Relazione Big Data

Progetto I: Daily Historical Stock Prices

Baldazzi Teodoro
teo.baldazzi@stud.uniroma3.it

Sferrazza Stefano
ste.sferrazza@stud.uniroma3.it

Maggio 2020

1 Introduzione

La seguente relazione illustra e documenta il lavoro di analisi, progettazione e realizzazione in linguaggio Java e HiveQL svolto come primo progetto del corso "Big Data" nell'anno accademico 2019/2020.
Di seguito i dettagli sui membri del gruppo:

- Baldazzi Teodoro, matr. 492471;
- Sferrazza Stefano, matr. 499264.

Il repository con il progetto svolto, le pseudo-codifiche e i risultati può essere trovato al seguente link: `https://github.com/StefanoSferrazza/BigData`, nonché allegato a questa relazione in formato compresso. Per alcuni esercizi sono state sviluppate più soluzioni, che si distinguono rispetto all'interpretazione delle richieste e all'implementazione adottata: a seguito della discussione con il docente, esse sono state mantenute e impiegate per lo svolgimento di test comparativi qui descritti.

La relazione è strutturata seguendo l'ordine delle varie fasi del lavoro, dall'analisi dei dataset al testing comparativo, come segue:

- la Sezione 2 introduce il dataset e le interpretazioni adottate in fase di analisi dei vari esercizi;
- la Sezione 3 fornisce una breve panoramica della struttura del progetto, per semplificarne l'esplorazione, nonché delle versioni degli esercizi sviluppate nelle varie tecnologie;
- la Sezione 4 illustra le pseudo-codifiche per le principali versioni degli esercizi in Hadoop e Spark, e le corrispondenti implementazioni in Hive;
- la Sezione 5 presenta e descrive in dettaglio le scelte implementative delle distinte versioni degli esercizi, nelle tre tecnologie, con riferimento al codice allegato a questa relazione;
- la Sezione 6 illustra i risultati delle esecuzioni nelle tre tecnologie, mostrando l'equivalenza dei record e del formato in output.
- la Sezione 7 descrive in dettaglio gli insiemi di test, con i corrispettivi grafici e tabelle, svolti per ogni esercizio e in ciascuna tecnologie, con dimensioni crescenti dell'input e distinti ambienti di esecuzione.

2 Analisi Dataset ed Esercizi

In questa Sezione è presentato il dataset *Daily Historical Stock Prices* fornito, con particolare riferimento alle proprietà osservate in fase di analisi dei dati e alle soluzioni conseguentemente adottate per favorire la corretta esecuzione degli esercizi, illustrate in maggior dettaglio nelle Sezioni successive. Inoltre sono sinteticamente descritti tali esercizi e le interpretazioni assunte per le fasi successive del lavoro. Si noti che, nel seguito della relazione, i termini "Esercizio" e "Job" (maiuscolo) siano impiegati come sinonimi.

Analisi Dataset

Il dataset comprende due file .CSV: *historical_stock_prices* (di seguito HSP) e *historical_stocks* (di seguito HS). Relativamente alle caratteristiche osservate sui dati in essi presenti, si può notare quanto segue:

- entrambi i file impiegano la virgola (",") come carattere separatore dei vari campi;
- HSP è il file di maggiore dimensione (pari a circa 2 GB) e descrive l'andamento giornaliero di un insieme di azioni in borsa, in termini di prezzi di apertura e chiusura. I record sono prevalentemente puliti, privi dunque di caratteri speciali o valori non corrispondenti ai tipi previsti per i corrispondenti campi;
- HS ha dimensione minore (pari a circa 430 KB) e fornisce informazioni su ciascuna azione, quali l'azienda e il settore di appartenenza; si noti che ciascun settore comprenda una o più aziende e ciascuna azienda sia associata a una o più azioni. Il file presenta diversi record con dati sporchi o assenti, per i quali dunque si ritiene necessaria una fase di pre-processamento: esempio tipico è la presenza di un valore nullo o vuoto in corrispondenza dei campi "settore" o "azienda". Si è inoltre osservata la presenza di una virgola nel nome di alcune aziende, nello specifico quelle terminanti per ", Inc." e sempre tra virgolette. Come vedremo, sono state impiegate opportune strategie di parsing e filtraggio per mantenere i dati corretti e completi.

Analisi Esercizi

Le specifiche progettuali richiedono lo sviluppo di 3 esercizi, ciascuno corrispondente a un job MapReduce (oppure a una chain di job, come vedremo nelle successive Sezioni) nelle tecnologie Hadoop, Hive e Spark. Per tutti gli esercizi, ogni richiesta associata a un prezzo fa riferimento ai prezzi di chiusura "close", mentre "open", "adj_close", "lowThe" e "highThe" non sono mai impiegati . Con riferimento ai singoli esercizi richiesti e alle informazioni sul dataset sopra fornite, si possono fare alcune osservazioni.

Primo Esercizio. Questo esercizio richiede informazioni ottenibili dal solo HSP e le specifiche fornite sono sufficienti per il suo svolgimento: variazione di quotazione e volume medio sono definiti come descritto e prezzo minimo e massimo si riferiscono a close minimo e massimo dell'intervallo per ciascun ticker.

Secondo Esercizio. Questo esercizio richiede di considerare sia HSP che HS. Dall'analisi si possono dedurre distinte interpretazioni per calcolare volume annuale, variazione annuale media e quotazione giornaliera media:

- come media di tutti i ticker del settore, trascurando dunque l'azienda di appartenenza di ciascun ticker;
- calcolando prima la media dei ticker di ciascuna azienda e poi la media delle aziende di ciascun settore;

Entrambe le versioni sono state soggetto di sviluppo e testing in questo progetto. Inoltre, per quanto concerne il calcolo della variazione annuale di un'azienda, si può considerare una distinta interpretazione rispetto alla media delle variazioni annuali dei ticker. Difatti, per variazione annuale di un'azienda si intende la differenza percentuale tra quotazione di fine anno e quotazione di inizio anno per l'azienda; inoltre la quotazione di un'azienda in un dato istante è definita come la somma delle quotazioni delle azioni ad essa appartenenti e attive in quel dato istante. Pertanto, la definizione impiegata in questo progetto per variazione annuale di un'azienda è la differenza percentuale tra la sommatoria dei close delle azioni alla fine dell'anno e la sommatoria dei close delle azioni all'inizio dell'anno.

Terzo Esercizio. Questo esercizio richiede di considerare sia HSP che HS. Il calcolo del trend come variazione di quotazione delle aziende è stato effettuato facendo riferimento alla definizione di cui sopra. Inoltre è stato considerato lo scenario facoltativo correlato (non presente nel progetto originale ma proposto dal docente via mail) in cui si voglia aggregare non solo aziende con medesimo trend, ma anche quelle che presentino un certo valore di similarità, definita a partire dalla differenza tra trend e calcolata mediante distanza euclidea.

3 Presentazione Progetto

In questa Sezione è illustrata la struttura del progetto allegato, per facilitarne l'esplorazione e la comprensione, con particolare riferimento alle versioni degli esercizi sviluppate nelle varie tecnologie e su cui sono stati effettuati test e comparazioni delle performance.

Struttura progetto

Il progetto è articolato come segue:

- in *src/main/java* sono presenti le implementazioni degli esercizi in Hadoop e Spark, nonché le classi di supporto *Utilities* per il pre-processing e il post-processing dei record;
- in *hive* sono presenti le implementazioni degli esercizi e l'inizializzazione delle tabelle per i dataset in Hive
- in *pseudo* sono presenti le pseudo-codifiche degli esercizi in Hadoop e Spark, mentre le corrispondenti implementazioni in Hive sono nella source folder di cui sopra;
- in *resultsFirst10* sono presenti i primi 10 record degli output dei job in Hadoop, Hive e Spark;
- in *resultsComplete* sono presenti i risultati completi delle versioni principali degli esercizi, ricavati dall'esecuzione delle implementazioni in Spark.

Versioni Esercizi

In questo progetto sono state sviluppate distinte versioni dei vari esercizi. Tali versioni si distinguono non solo per le interpretazioni delle varie richieste nelle specifiche progettuali, come introdotto in Sezione 2, ma anche per le scelte adottate nell'implementazione ai fini di presentare comparazioni delle performance interessanti e di una certa rilevanza. Di seguito esse sono brevemente presentate rispetto alla tecnologia adottata: nella Sezione 5 sono analizzate con maggior dettaglio le principali (*main* in Hive) e nella Sezione 7 sono impiegate per i confronti delle performance. Si noti che, pur non avendo effettuato test specifici per la valutazione delle prestazioni su ogni versione implementata, poiché non rilevanti in alcuni casi ai fini del lavoro in questione, sia tuttavia stato ritenuto utile mantenerle tutte nel codice allegato, per mostrare il lavoro svolto nel suo complesso e in ogni sua diramazione.

Hadoop. Nella tecnologia Hadoop sono state sviluppate le seguenti versioni degli esercizi.

- esercizio 1: in questa tecnologia presenta una singola versione;
- esercizio 2: presenta una versione *basic*, in cui non si considera l'azienda e i campi richiesti sono calcolati ragionando in termini di ticker e settore, una versione *complex*, che al contrario considera anche l'azienda, e una versione *complex con combiner* per l'analisi degli effetti del combiner sulle prestazioni;
- esercizio 3: in questa tecnologia è presente una singola versione.

Hive. Nella tecnologia Hive sono state sviluppate le seguenti versioni degli esercizi.

- esercizio 1: presenta una versione *main*, caratterizzata da una singola temporary table, una versione *altern*, che invece presenta un maggior numero di temporary tables, e una versione *res*, analoga a *main* fatta eccezione per il formato dei record in output (impiegata per costruire l'output in questa relazione);
- esercizio 2: presenta una versione *basic*, in cui non si considera l'azienda e i campi richiesti sono calcolati ragionando in termini di ticker e settore, e una versione *complex*, che al contrario considera anche l'azienda;
- esercizio 3: presenta due versioni *main* e *altern*, che si distinguono per la definizione e il calcolo della variazione annuale media, come introdotto in Sezione 2, una versione *res* analoga a *main* fatta eccezione per il formato dei record in output (impiegata per costruire l'output in questa relazione), e infine una versione *facoltativa* che implementa la similarità tra aziende per le quali non ne esistano altre con trend equivalente.

Spark. Nella tecnologia Spark sono state sviluppate le seguenti versioni degli esercizi.

- esercizio 1: in questa tecnologia è presente una singola versione;
- esercizio 2: presenta una versione *singleRow* e una versione *distributedRows*. Le funzioni utilizzate nelle due versioni sono identiche, ma si ha una differenza nella distribuzione delle funzioni utilizzate su più strutture intermedie al fine di osservare se questo comporti differenze in termini di prestazioni.
- esercizio 3: in questa tecnologia è presente una singola versione.

4 Pseudocodice

In questa Sezione sono illustrate le pseudo-codifiche delle principali soluzioni per ciascun esercizio, nelle tecnologie Hadoop e Spark, e le corrispondenti implementazioni in Hive. Per ciascuna sono fornite pre-condizioni e post-condizioni. Si rimanda alla Sezione 5 per la dettagliata discussione sulle scelte implementative nelle varie tecnologie. Per ragioni di spazio, sono stati rimossi alcuni commenti e spazi: nella cartella *pseudo* del progetto sono presenti i file con le seguenti pseudo-codifiche e nella cartella *hive* si possono trovare le corrispondenti versioni complete in Hive.

4.1 Hadoop

```
HADOOP EX1

INPUT:
 - path to document "historical_stock_prices.csv".
 - path for output result.

PRE-COND:
 - path to historical_stock_prices.csv needs to be valid.
 - historical_stock_prices.csv needs to be a document, separated
   by commas, with 8 fields:
   - TICKER            String       unique share symbol
   - OPEN       Float       open price
   - CLOSE             Float        close price
   - ADJ_CLOSE  Float       adjusted close price
   - LOW       Float        min price
   - HIGH              Float        max price
   - VOLUME     Long                number of transactions
   - DATE    Date          date in format yyyy-mm-dd
- output path needs to be valid.

POST-COND:
- output file needs to be a document, separated by commas, with 5
  fields:
  - TICKER    String
  - DELTA_QUOTATION_% String  (Integer with %)  percentage change
                    rounded of ticker value in period 2008-2018
  - MIN_CLOSE    Float   min "close" value reported in
                         period 2008-2018
  - MAX_CLOSE    Float   max "close" value reported in period
                         2008-2018
  - AVG_VOLUME   Long    average "volume" in period 2008-2018
- document rows need to be sorted by descending DELTA_QUOTATION
```

```
ex1Mapper(key, value)
  skip first row                                        //header
  check_correctness_data(value)                         //correct types
  close,volume,date <- extractRelevantValues(value)     //relevant values are
                                                       "close","volume","date"
  key <- extractTicker(value)

  if (2008 <= date.year() && date.year() <= 2018):
     EMIT(ticker, (close, volume, date))


ex1Reducer(key, values)
  initialize firstClose, lastClose, firstDate, lastDate,
             minClose, maxClose, sumVolumes, numValues

  for each text in values:
     update firstClose, lastClose, firstDate, lastDate,
            minClose, maxClose, sumVolumes, numValues
     if(text.date < firstDate)
         firstDate = text.date
         firstClose = text.close
     if(text.date > lastDate)
         lastDate = text.date
         lastClose = text.close
     if(text.close < minClose)
         minClose = close
     if(text.close > maxClose)
         maxClose = close
         sumVolumes += text.volume
         numValues++

     deltaQuotation = ((lastClose - firstClose) / firstClose) * 100
     avgVolume = sumVolumes / numValues

     EMIT(ticker, (deltaQuotation,minClose,maxClose,avgVolume))
```

Figura 1: Hadoop Esercizio 1 con pre e post condizioni

```
HADOOP EX 2 BASIC

INPUT:
 - path to document "historical_stock_prices.csv".
 - path to document "historical_stocks.csv".
 - path for temp result.
 - path for output result.

PRE-COND:
 - path to historical_stock_prices.csv needs to be valid.
 - path to historical_stocks.csv needs to be valid.
 - historical_stock_prices.csv needs to be a document, separated
by commas, with 8 fields:
   - TICKER       String            unique share symbol
   - OPEN         Float             open price
   - CLOSE        Float             close price
   - ADJ_CLOSE    Float             adjusted close price
   - LOW          Float             min price
   - HIGH         Float             max price
   - VOLUME       Long              number of transactions
   - DATE         Date              date in format yyyy-mm-dd
- historical_stocks.csv needs to be a document, separated by
commas, with 5 fields:
   - TICKER       String            unique share symbol
   - EXCHANGE     String            NYSE or NASDAQ
   - NAME         String            company name
   - SECTOR       String            sector name
   - INDUSTRY     String            industry name
- temp path needs to be valid.
- output path needs to be valid.

POST-COND:
- output file needs to be a document, separated by commas, with 5
fields:
   - SECTOR       String
   - YEAR         String      between 2008-2018
   - avgVolume    Long        average annual volume of sector
                              reported in period 2008-2018
   - DELTA_QUOTATION_%  String    (Integer with %)     percentage
                                   change rounded of volume
                                   reported in period 2008-2018
   - avgDailyClose      Long    average daily quotation of sector
                                reported in period 2008-2018
```

```
ex2HSPMapper(key, value)
  skip first row                    //header
  check_correctness_data(value)     //correct types and date in correct period
  close,volume,date <- extractRelevantValues(value)    //relevant values are
                                                      "close","volume","date"
  key <- extractTicker(value)

  if (2008 <= date.year() && date.year() <= 2018):
     EMIT(ticker, (close, volume, date))

ex2HSMapper(key, value)
  skip first row                    //header
  check_correctness_data(value)     //correct types and date in correct period
  sector <- extractRelevantValues(value)      //relevant value is "sector"
  key <- extractTicker(value)

  EMIT(ticker, sector)

ex2JoinReducer(key, values)
  initialize maps actionYearFirstDate, actionYearLastDate, actionYearFirstClose,
                  actionYearLastClose, actionYearSumVolume,
                  actionYearSumDailyClose, actionYearNumRows
  sector <- values.get()
  close,volume,date <- values.get()

  for each text in values:
   update actionYearFirstDate, actionYearLastDate, actionYearFirstClose,
          actionYearLastClose, actionYearSumVolume,
          actionYearSumDailyClose, actionYearNumRows

  for each year in actionYearFirstClose:
   lastClose <- actionYearLastClose.get(year)
   firstClose <- actionYearFirstClose.get(year)
   deltaQuotation <- ((lastClose - firstClose) / firstClose) * 100

   sumVolume <- actionYearSumVolume.get(year)
   sumDailyClose <- actionYearSumDailyClose.get(year)
   yearRow <- actionYearNumRows.get(year)

   EMIT((sector,year), (sumVolume,deltaQuotation,sumDailyClose,yearRow))

ex2Mapper(key, value)
  sumVolume,deltaQuotation,sumDailyClose,yearRow <- extractRelevantValues(value)
  EMIT((sector,year), (sumVolume,deltaQuotation,sumDailyClose,yearRow))

ex2Reducer(key, values)
  initialize sectorSumVolume, sectorSumDeltaQuotation, sectorSumDailyClose,
             sectorYearRows, counterRows

  for each text in values:
    update sectorSumVolume, sectorSumDeltaQuotation, sectorSumDailyClose,
                                sectorYearRows, counterRows

  avgSumVolume <- sectorSumVolume/counterRows
  avgDeltaQuot <- sectorSumDeltaQuotation/counterRows
  avgDailyClose <- sectorSumDailyClose/sectorYearRows

  EMIT((sector,year), (avgSumVolume,avgDeltaQuot,avgDailyClose))
```

Figura 2: Hadoop Esercizio 2 Basic con pre e post condizioni

```
HADOOP EX 2 WITH_COMPANIES

INPUT:
 - path to document "historical_stock_prices.csv".
 - path to document "historical_stocks.csv".
 - path for temp results.
 - path for output result.

PRE-COND:
 - path to historical_stock_prices.csv needs to be valid.
 - path to historical_stocks.csv needs to be valid.
 - historical_stock_prices.csv needs to be a document, separated
by commas, with 8 fields:
   - TICKER       String            unique share symbol
   - OPEN         Float             open price
   - CLOSE        Float             close price
   - ADJ_CLOSE    Float             adjusted close price
   - LOW          Float             min price
   - HIGH         Float             max price
   - VOLUME       Long              number of transactions
   - DATE         Date              date in format yyyy-mm-dd
- historical_stocks.csv needs to be a document, separated by
commas, with 5 fields:
   - TICKER       String            unique share symbol
   - EXCHANGE     String            NYSE or NASDAQ
   - NAME         String            company name
   - SECTOR       String            sector name
   - INDUSTRY     String            industry name
- temp paths need to be valid.
- output path needs to be valid.


POST-COND:
- output file needs to be a document, separated by commas, with 5
fields:
   - SECTOR    String
   - YEAR     String          between 2008-2018
   - avgVolume     Long        average annual volume of sector
                               reported in period 2008-2018
   - DELTA_QUOTATION_%     String   (Integer with %)  percentage
           change rounded of volume reported in period 2008-2018
   - avgDailyClose          Long     average daily quotation of
                              sector reported in period 2008-2018
```

```
ex2HSPMapper(key, value)
  skip first row                    //header
  check_correctness_data(value)     //correct types and date in correct period
  close,volume,date <- extractRelevantValues(value)    //relevant values are
                                                       "close","volume","date"
  key <- extractTicker(value)

  if (2008 <= date.year() && date.year() <= 2018):
     EMIT(ticker, (close, volume, date))

ex2HSMapper(key, value)
  skip first row                    //header
  check_correctness_data(value)     //correct types and date in correct period
  sector <- extractRelevantValues(value)      //relevant value is "sector"
  key <- extractTicker(value)

  EMIT(ticker, (sector,company))

ex2JoinReducer(key, values)
  initialize maps actionYearFirstDate, actionYearLastDate, actionYearFirstClose,
                  actionYearLastClose, actionYearSumVolume,
                  actionYearSumDailyClose, actionYearNumRows
   company,sector <- values.get()
   close,volume,date <- values.get()

   for each text in values:
      update actionYearFirstDate, actionYearLastDate, actionYearFirstClose,
             actionYearLastClose, actionYearSumVolume,
             actionYearSumDailyClose, actionYearNumRows

   for each year in actionYearFirstClose:
      lastClose <- actionYearLastClose.get(year)
      firstClose <- actionYearFirstClose.get(year)

      sumVolume <- actionYearSumVolume.get(year)
      sumDailyClose <- actionYearSumDailyClose.get(year)
      yearRow <- actionYearNumRows.get(year)
      EMIT((company,sector,year),(sumVolume,lastClose,firstClose,
           sumDailyClose,yearRow))

ex2CompanyMapper(key, value)
   sumVolume,lastClose,firstClose,sumDailyClose,yearRow <-
                                                    extractRelevantValues(value)
   EMIT((sector,year), (sumVolume,lastClose,firstClose,sumDailyClose,yearRow))

ex2CompanyReducer(key, values)
   initialize companySumYearVolume, companySumLastCloses, companySumFirstCloses,
              companySumDailyCloses, companyYearRows

   for each text in values:
      update companySumYearVolume, companySumLastCloses, companySumFirstCloses,
             companySumDailyCloses, companyYearRows

   companyDeltaQuotation <- ((companySumLastCloses-
                              companySumFirstCloses)/companySumFirstCloses)*100
   companyAvgDailyClose <- companySumDailyCloses/companyYearRows

   EMIT((sector,year),
        (companySumYearVolume,companyDeltaQuotation,companyAvgDailyClose))

ex2SectorMapper(key, value)
    companySumYearVolume,companyDeltaQuotation,companyAvgDailyClose <-
                                                    extractRelevantValues(value)
    EMIT((sector,year),
             (companySumYearVolume,companyDeltaQuotation,companyAvgDailyClose))

ex2SectorReducer(key, values)
    initialize sectorSumVolume, sectorSumDeltaQuotation,
               sectorSumDailyClose, counterCompanies

    for each text in values:
       update sectorSumVolume, sectorSumDeltaQuotation,
              sectorSumDailyClose, counterCompanies

    avgSumVolume <- sectorSumVolume / counterCompanies
    avgDeltaQuot = sectorSumDeltaQuotation / counterCompanies
    avgDailyClose = sectorSumDailyClose / counterCompanies

    EMIT((sector,year), (avgSumVolume,avgDeltaQuot,avgDailyClose))
```

Figura 3: Hadoop Esercizio 2 Complex con pre e post condizioni

```
HADOOP EX 3

INPUT:
 - path to document "historical_stock_prices.csv".
 - path to document "historical_stocks.csv".
 - path for temp result.
 - path for output result.

PRE-COND:
 - path to historical_stock_prices.csv needs to be valid.
 - path to historical_stocks.csv needs to be valid.
 - historical_stock_prices.csv needs to be a document, separated
by commas, with 8 fields:
   - TICKER       String            unique share symbol
   - OPEN         Float             open price
   - CLOSE        Float             close price
   - ADJ_CLOSE    Float             adjusted close price
   - LOW          Float             min price
   - HIGH         Float             max price
   - VOLUME       Long              number of transactions
   - DATE         Date              date in format yyyy-mm-dd
- historical_stocks.csv needs to be a document, separated by
commas, with 5 fields:
   - TICKER       String            unique share symbol
   - EXCHANGE     String            NYSE or NASDAQ
   - NAME         String            company name
   - SECTOR       String            sector name
   - INDUSTRY     String            industry name
- temp path needs to be valid.
- output path needs to be valid.


POST-COND:
- output file needs to be a document, separated by commas, with 5
fields:
    - SIMILARITIES   String[]    list of companies with same
                                 trend in year 2016-2018
    - TREND     Integer[3]  percentage variation of company in
                            year 2016,2017,2018
```

```
ex3HSPMapper(key, value)
   skip first row           //header
   check_correctness_data(value)     //correct types and date in correct period
   close,volume,date <- extractRelevantValues(value)   //relevant values are
                                                        "close","volume","date"
   key <- extractTicker(value)

   if (2008 <= date.year() && date.year() <= 2018):
      EMIT(ticker, (close, volume, date))

ex3HSMapper(key, value)
   skip first row       //header
   check_correctness_data(value)     //correct types and date in correct period
   company <- extractRelevantValues(value)    //relevant value is "company"
   key <- extractTicker(value)

   EMIT(ticker, company)

ex3JoinReducer(key,values)
   SETUP phase
       initialize maps companyYearStartQuotation, companyYearEndQuotation,
                    companyAnnualVariations

   REDUCE phase
      joinValuesOn(key)
      initialize maps yearFirstDate,yearLastDate,yearFirstClose,yearLastClose
      for each value in values
         year <- value.year
         firstDate <- MIN(value.date,yearFirstDate.get(year))
         lastDate <- MAX(value.date,yearLastDate.get(year))
         firstClose <- close associated to firstDate
         lastClose <- close associated to lastDate
         update maps pair with key year

      for each year in yearFirstDate
         firstClose <- yearFirstClose.get(year)
         lastClose <- yearLastClose.get(year)
         sumFirstCloses <- companyYearStartQuotation.get(company,year) +
                           firstClose
         sumLastCloses <- companyYearEndQuotation.get(company,year) + lastClose
         update maps companyYearStartQuotation,
                     companyYearEndQuotation with key company,year

    CLEANUP phase
         for each company,year in companyYearStartQuotation
             sumFirstCloses <- companyYearStartQuotation.get(companyYear)
             sumLastCloses <- companyYearStartQuotation.get(companyYear)
             companyAnnualVariation <- ((sumLastCloses - sumFirstCloses)
                                        /sumFirstCloses)*100
         update companyAnnualVariations with key company and value
                                    companyAnnualVariation for respective year

         EMIT(company,(companyAnnualVariations.get(company)))

Ex3Mapper(key,value)
         checkCorrectValues(value)
         EMIT(key,value)

Ex3Reducer(key,values)
   SETUP phase
         initialize maps companiesNumbers,companiesQuotations
         EMIT(header)

   REDUCE phase
         for each value in values
            companies <- append value.company
            counterCompanies <- companies.length
         if(counterCompanies>1)
            update maps companiesNumbers,companiesQuotations

   CLEANUP phase
         for each comps in companiesNumbers
            numberOfCompanies <- companiesNumbers.get(comps)
            trend <- companiesQuotations.get(comps)

            EMIT(numberOfCompanies, (comps,trend))
```

Figura 4: Hadoop Esercizio 3 con pre e post condizioni

4.2 Spark

```
SPARK EX 1

INPUT:
 - path to document "historical_stock_prices.csv".
 - path for output result.

PRE-COND:
 - path to historical_stock_prices.csv needs to be valid.
 - historical_stock_prices.csv needs to be a document, separated
   by commas, with 8 fields:
   - TICKER            String       unique share symbol
   - OPEN       Float       open price
   - CLOSE             Float        close price
   - ADJ_CLOSE  Float       adjusted close price
   - LOW       Float        min price
   - HIGH              Float        max price
   - VOLUME     Long                number of transactions
   - DATE    Date          date in format yyyy-mm-dd
- output path needs to be valid.

POST-COND:
- output file needs to be a document, separated by commas, with 5
  fields:
  - TICKER    String
  - DELTA_QUOTATION_% String  (Integer with %)  percentage change
                     rounded of ticker value in period 2008-2018
  - MIN_CLOSE    Float   min "close" value reported in
                         period 2008-2018
  - MAX_CLOSE    Float   max "close" value reported in period
                         2008-2018
  - AVG_VOLUME   Long    average "volume" in period 2008-2018
- document rows need to be sorted by descending DELTA_QUOTATION
```

```
main
  valuesHSP <- checkline(inputHSP).prepareValues

  valuesHSP.prepareValues(line)
            .reducer(tuple1, tuple2)
            .produceResults(tuple)
            .descendentSort(result.percentageChange)

checkline(line)    //filter dirty rows
   if (check_correctness_data(line) &&                  //correct types
      2008 <= date.year() && date.year() <= 2018):
           return true
   return false

prepareValues(line)        //organize data for later manipulation
    firstDate,lastDate <- line.date
    firstClose,lastClose,minClose,maxClose <- line.close
    volume <- line.volume
    counter <- 1

     key <- ticker
     value <- firstDate,lastDate,firstClose,lastClose,
              minClose,maxClose,volume,counter
     EMIT(key,value)

reducer(tuple1, tuple2)    //aggregate on ticker
     firstDate <- MIN(tuple1.date , tuple2.date)
     lastDate <- MAX(tuple1.date , tuple2.date)
     firstClose <- close associated to firstDate
     lastClose <- close associated to lastDate
     minClose <- MIN(tuple1.close , tupl2.close)
     maxClose <- MAX(tuple1.close , tupl2.close)
     sumVolume <- tuple1.volume + tuple2.volume
     counter <- tuple1.counter + tuple2.counter

     value <- firstDate,lastDate,firstClose,lastClose,
              minClose,maxClose,sumVolume,counter
     EMIT(value)

produceResults(tuple)    //calculate results
     ticker <- tuple.ticker
     percentageChange <- ((tuple.lastClose - tuple.firstClose) /
                          tuple.firstClose) * 100
     minPrice <- tuple.minPrice
     maxPrice <- tuple.maxPrice
     avgVolume <- tuple.volume / tuple.counter

     result <- ticker, percentageChange, minPrice, maxPrice, avgVolume
     EMIT(result)
```

Figura 5: Spark Esercizio 1 con pre e post condizioni

```
SPARK EX 2

INPUT:
 - path to document "historical_stock_prices.csv".
 - path to document "historical_stocks.csv".
 - path for output result.

PRE-COND:
 - path to historical_stock_prices.csv needs to be valid.
 - path to historical_stocks.csv needs to be valid.
 - historical_stock_prices.csv needs to be a document, separated
by commas, with 8 fields:
   - TICKER       String            unique share symbol
   - OPEN         Float             open price
   - CLOSE        Float             close price
   - ADJ_CLOSE    Float             adjusted close price
   - LOW          Float             min price
   - HIGH         Float             max price
   - VOLUME       Long              number of transactions
   - DATE         Date              date in format yyyy-mm-dd
- historical_stocks.csv needs to be a document, separated by
commas, with 5 fields:
   - TICKER       String             unique share symbol
   - EXCHANGE     String             NYSE or NASDAQ
   - NAME         String             company name
   - SECTOR       String             sector name
   - INDUSTRY     String             industry name
- output path needs to be valid.


POST-COND:
- output file needs to be a document, separated by commas, with 5
fields:
   - SECTOR    String
   - YEAR     String          between 2008-2018
   - avgVolume      Long    average annual volume of sector
reported in period 2008-2018
   - DELTA_QUOTATION_%  String       (Integer with
                              percentage change rounded of
                         volume reported in period 2008-2018
   - avgDailyClose    Long average daily quotation of
                         sector reported in period 2008-2018
```

```
main
          valuesHSP <- checkInputHSP(inputHSP).prepareValuesHSP
          valuesHS <- checkInputHSP(inputHS).prepareValuesHS
          valuesHSP.join(valuesHS) .reorganizeValuesAfterJoin
               .reduce_sumVolumesTicker_findFirstLastClose.map_fromTickerToCompany
               .reduce_sumVolumeCompany_SumFirstLastCloseCompany_sumCloseSumCounterCompan
               .map_varYearCompany_dailyQuotCompany_fromCompanyToSector
               .reduce_sumVolumes_sumVars_sumQuots.map_avgSector.sortBy(key);

checkInputHS(line)             //filter dirty rows
          if(check_correctness_data(line))//correct types
                    return true
          return false
checkInputHSP(line)        //filter dirty rows
          if (check_correctness_data(line) &&        //correct types
                              2008 <= date.year() && date.year() <= 2018):
                    return true
          return false

prepareValuesHS(line)//take relevant fields from historical_stocks
          company,sector <- extractValues(line)
          key <- line.ticker
          value <- company,sector
          EMIT(key,value)

prepareValuesHSP(line)//take relevant fields from historical_stock_prices
          close,volume,date <- extractValues(line)
          key <- line.ticker
          value <- close,volume,date
          EMIT(key, value)

reorganizeValuesAfterJoin(tuple)          //organize values for later computation
          volume <- tuple.volume
          firstDate,lastDate <- tuple.date
          firstClose,lastClose,close <- tuple.close
          counterDays <- 1
          company <- tuple.company
          sector <- tuple.sector
          key <- tuple.ticker + tuple.year
          value <-
volume,firstDate,lastDate,firstClose,lastClose,close,counterDays,company,sector
          EMIT(key, value)

reduce_sumVolumesTicker_findFirstLastClose(tuple1, tuple2)
          //aggregate values on tickers
          sumVolume <- tuple1.volume + tuple2.volume
          firstDate <- MIN(tuple1.date, tuple2.date)
          lastDate <- MAX(tuple1.date, tuple2.date)
          firstClose <- close associated to firstDate
          lastClose <- close associated to lastDate
          sumClose <- tuple1.close + tupl2.close
          counterDays <- tuple1.counterDays + tupl2.counterDays
          company <- tuple1.company
          sector <- tuple1.sector
          value <-
sumVolume,firstDate,lastDate,firstClose,lastClose,sumClose,counterDays,company,sector
          EMIT(value)

map_fromTickerToCompany(tuple)   //change key to company year
      sumVolume,firstClose,lastClose,sumClose,counterDays,sector <- extractValues(tuple)
          key <- tuple.company + tuple.year
          value <- sumVolume,firstClose,lastClose,sumClose,counterDays,sector
          EMIT(key,value)

reduce_sumVolumeCompany_SumFirstLastCloseCompany_sumCloseSumCounterCompany
 (tuple1, tuple2)          //aggregate on company,year
          sumVolumeCompany <- tuple1.volume + tuple2.volume
          sumFirstCloses <- tuple1.firstClose + tuple2.firstClose
          sumLastCloses <- tuple.lastClose + tuple2.lastClose
          sumCloses <- tuple1.close + tuple2.close
          smCountersDays <- tuple1.counterDays + tuple2.counterDays
          sector <- tuple1.sector
          value <- sumVolumeCompany,sumFirstCloses,sumLastCloses,
                    sumCloses,sumCountersDays,sector
          EMIT(value)

map_varYearCompany_dailyQuotCompany_fromCompanyToSector(tuple)
//aggregate companies and change key to sector year
     sumVolume <- tuple.sumVolumeCompany
     varYear <- ((tuple.lastCloses - tuple.firstCloses) / tuple.firstCloses) * 100
     dailyQuot <- tuple.sumCloses / tuple.sumCountersDays
     counterCompanies <- 1
     key <- tuple.sector + tuple.year
     value <- sumVolume,varYear,dailyQuot,counterCompanies
     EMIT(key,value)

reduce_sumVolumes_sumVars_sumQuots(tuple1, tuple2)   //aggregato on sector year
     sumVolumes <- tuple1.volume + tuple2.volume
     sumVars <- tuple1.varYear + tuple2.varYear
     sumQuots <- tuple1.dailyQuot + tuple2.dailyQuot
     counterCompanies <- tuple1.counterCompanies + tuple2.counterCompanies
     value <- sumVolumes,sumVars,sumQuots,counterCompanies
     EMIT(value)

map_avgSector(tuple) //compute results
          sectorYear <- tuple.key
          avgVolumes <- tuple.sumVolumes / tuple.counterCompanies
          avgVars <- tuple.sumVars / tuple.counterCompanies
          avgDailyQuots <- tuple.sumQuots / tuple.counterCompanies
          result <- sectorYear,avgVolumes,avgVars,avgDailyQuots
          EMIT(result)
```

Figura 6: Spark Esercizio 2 Complex con pre e post condizioni

```
SPARK EX 3

INPUT:
 - path to document "historical_stock_prices.csv".
 - path to document "historical_stocks.csv".
 - path for temp result.
 - path for output result.

PRE-COND:
 - path to historical_stock_prices.csv needs to be valid.
 - path to historical_stocks.csv needs to be valid.
 - historical_stock_prices.csv needs to be a document, separated
by commas, with 8 fields:
   - TICKER       String            unique share symbol
   - OPEN         Float             open price
   - CLOSE        Float             close price
   - ADJ_CLOSE    Float             adjusted close price
   - LOW          Float             min price
   - HIGH         Float             max price
   - VOLUME       Long              number of transactions
   - DATE         Date              date in format yyyy-mm-dd
- historical_stocks.csv needs to be a document, separated by
commas, with 5 fields:
   - TICKER       String            unique share symbol
   - EXCHANGE     String            NYSE or NASDAQ
   - NAME         String            company name
   - SECTOR       String            sector name
   - INDUSTRY     String            industry name
- temp path needs to be valid.
- output path needs to be valid.

POST-COND:
- output file needs to be a document, separated by commas, with 5
fields:
   - SIMILARITIES  String[]list of companies with same trend in
year 2016-2018
   - TRENDInteger[3]       percentage variation of company in
                           year 2016,2017,2018
```

```
main
          valuesHSP <- checkInputHSP(inputHSP).prepareValuesHSP
          valuesHS <- checkInputHSP(inputHS).prepareValuesHS
          valuesHSP.join(valuesHS).reorganizeValuesAfterJoin
              .reduce_findFirstLastCloses.map_fromTickerToCompany
              .reduce_sumFirstLastCloses .map_calculateVarPercCompanyYear_changeKeyToCompany
              .reduce_unifyTrends.checkAllYearPresent
              .invertKey_fromCompany_toVarYear.reduce_companySameTrend
              .mapByNumberSimilarCompaniesTrend.sortBy(similarities.length);

checkInputHS(line)    //filter dirty rows
          if(check_correctness_data(line))//correct types
                    return true
          return false
checkInputHSP(line)  //filter dirty rows
          if (check_correctness_data(line) &&   //correct types
                              2016 <= date.year() && date.year() <= 2018):
                    return true
          return false
prepareValuesHS(line)           //take relevant fields from historical_stocks
          company,sector <- extractValues(line)
          key <- line.ticker
          value <- company,sector
          EMIT(key,value)
prepareValuesHSP(line)    //take relevant fields from historical_stock_prices
          close,volume,date <- extractValues(line)
          key <- line.ticker
          value <- close,volume,date
          EMIT(key, value)
reorganizeValuesAfterJoin(tuple)    //prepare values for later computation
          firstDate,lastDate <- tuple.date
          firstClose,lastClose <- tuple.close
          company <- tuple.company
          key <- tuple.ticker + tuple.year
          value <- firstDate,lastDate,firstClose,lastClose,company
          EMIT(key,value)

reduce_findFirstLastCloses(tuple1,tuple2)   //aggregate on ticker
          firstDate <- MIN(tuple1.date,tuple2.date)
          lastDate <- MAX(tuple1.date,tuple2.date)
          firstClose <- close associated to firstDate
          lastClose <- close associated to lastDate
          company <- tuple1.company
          value <- firstDate,lastDate,firstClose,lastClose,company
          EMIT(value)

map_fromTickerToCompany(tuple)            //change key to company
          firstClose <- tuple.firstClose
          lastClose <- tuple.lastClose
          key <- tuple.company + tuple.year
          value <- firstClose,lastClose
          EMIT(key,value)

reduce_sumFirstLastCloses(tuple1,tuple2)   //aggregate on company
          sumFirstCloses <- tuple1.firstClose + tuple2.firstClose
          sumLastCloses <- tuple1.lastClose + tuple2.lastClose
          value <- sumFirstCloses,sumLastCloses
          EMIT(value)
map_calculateVarPercCompanyYear_changeKeyToCompany(tuple)
          //calculate percentage variation and change key to company
          varYear2016,varYear2017,varYear2018 <- null
          varyear <- ((tuple.sumLastCloses - tuple.sumFirstCloses) /
tuple.sumFirstCloses)*100
          update correspondent VarYear variables according to tuple.year
          key <- tuple.company
          value <- varYear2016,varYear2017,varYear2018
          EMIT(key,value)
reduce_unifyTrends(tuple1,tuple2)  //unify percentage variation of year on a single record
          varYear2016 <- tuple1.varYear2016
          varYear2017 <- tuple1.varYear2017
          varYear2018 <- tuple1.varYear2017
          if(varYear2016==NULL)
                    varYear2016 <- tuple2.varYear2016
          if(varYear2017==NULL)
                    varYear2017 <- tuple2.varYear2017
          if(varYear2018==NULL)
                    varYear2018 <- tuple2.varYear2018

          value <- varYear2016,varYear2017,varYear2018
          EMIT(value)
checkAllYearPresent(tuple) //filter those that doesn't have var percentage for 2016-2017-2018
          if(tuple.varYear2016==NULL ||tuple.varYear2017==NULL ||tuple.varYear2018==NULL)
                    return false
          return true
invertKey_fromCompany_toVarYear(tuple)
          //change key to trend
          varYear2016,varYear2017,varYear2018 <- extractValues(tuple)

          key <- varYear2016,varYear2017,varYear2018
          value <- tuple.company
          EMIT(key,value)
reduce_companySameTrend(tuple1,tuple2)     //unify companies with same trend
          value <- tuple1.company, tuple2.company
          EMIT(value)
mapByNumberSimilarCompaniesTrend(tuple)
                              //calculate number of similarities to order results and
change key to that value
          key <- tuple.companies.length
          value <- tuple.companies + tuple.varYear2016 + tuple.varYear2017 +
tuple.varYear2018
          EMIT(key,value)
```

Figura 7: Spark Esercizio 3 con pre e post condizioni

4.3 Hive

```
HIVE EX 1

DROP TABLE if exists ticker_firstlastvalues;

CREATE TEMPORARY TABLE ticker_firstlastvalues
AS
SELECT ticker as ticker,
            MIN(day) as first_date,
            MAX(day) as last_date,
            MIN(close) as min_close,
       MAX(close) as max_close,
       FLOOR(AVG(volume)) as avg_volume
FROM historical_stock_prices
WHERE year(day) between '2008' and '2018'
GROUP BY ticker;



---------- VERSION WITHOUT TEMPORARY TABLES ----------
DROP TABLE if exists ex1_hive;

CREATE TABLE ex1_hive
ROW FORMAT DELIMITED FIELDS TERMINATED by ','
AS
SELECT tfc.ticker as ticker,
       ROUND(((last_close - first_close)/first_close)*100, 0) as d_quot,
       min_close,
       max_close,
       avg_volume
FROM ( SELECT tfd.ticker as ticker,
              hsp.close as first_close,
              min_close,
              max_close,
              avg_volume
       FROM ticker_firstlastvalues tfd
       JOIN historical_stock_prices hsp
                    ON (tfd.ticker = hsp.ticker and tfd.first_date = hsp.day)
          ) tfc
JOIN ( SELECT tld.ticker as ticker,
                   hsp.close as last_close
            FROM ticker_firstlastvalues tld
            JOIN historical_stock_prices hsp
                      ON (tld.ticker = hsp.ticker and tld.last_date = hsp.day)
     ) tlc
ON (tfc.ticker = tlc.ticker)
ORDER BY d_quot desc;
```

Figura 8: Hive Esercizio 1 Main hql

```
HIVE EX 2 BASIC

DROP TABLE if exists ticker_sector;

CREATE TEMPORARY TABLE ticker_sector
AS
SELECT hs.ticker as ticker,
       sector,
       volume,
       close,
       day
FROM historical_stocks hs JOIN historical_stock_prices hsp
          ON hs.ticker = hsp.ticker
WHERE year(day) between '2008' and '2018'
           and sector != 'N/A';



DROP TABLE if exists ticker_sector_year;

CREATE TEMPORARY TABLE ticker_sector_year
AS
SELECT ticker,
             sector,
       year(day) as year,
       SUM(volume) as volumes,
       SUM(close) as closes,
       MIN(day) as first_date,
       MAX(day) as last_date,
       COUNT(*) as num
FROM ticker_sector
GROUP BY ticker, sector, year(day);



DROP TABLE if exists ex2basic_hive;

CREATE TABLE ex2basic_hive
ROW FORMAT DELIMITED FIELDS TERMINATED BY ','
AS
SELECT tmp.sector as sector,
       tmp.year as year,
       cast(AVG(tmp.volumes) as BIGINT) as avgVolume,
       ROUND(AVG(((ts.close - first_close) / first_close) * 100), 2) as delta_quot,
       ROUND(SUM(tmp.closes) / SUM(num), 2)
FROM
          ( SELECT ty.ticker,
                   ty.sector,
                   ty.year,
                   ty.volumes,
                   ty.closes,
                   ts.close as first_close,
                   last_date,
                   num
            FROM ticker_sector_year ty JOIN ticker_sector ts
                  ON  ty.ticker = ts.ticker
                  and ty.sector = ts.sector
                  and ty.year = year(ts.day)
                  and ty.first_date = ts.day ) tmp
JOIN ticker_sector ts
     ON  tmp.ticker = ts.ticker
     and tmp.sector = ts.sector
     and tmp.year = year(ts.day)
     and last_date = ts.day
GROUP BY tmp.sector, tmp.year;
```

Figura 9: Hive Esercizio 2 Basic hql

```
HIVE EX 2 COMPLEX

DROP TABLE if exists ticker_firstlastdateyear;
CREATE TEMPORARY TABLE ticker_firstlastdateyear
AS
SELECT hs.ticker,
            company,
            sector,
            year(day) as year,
            SUM(volume) as totvolume_ticker,
            MIN(day) as firstdate_ticker,
            MAX(day) as lastdate_ticker,
            SUM(close) as totclose_ticker,
            COUNT(*) as totcount_ticker
FROM historical_stocks hs JOIN historical_stock_prices hsp
          ON hs.ticker = hsp.ticker
WHERE year(day) between '2008' and '2018'
           and sector != 'N/A'
           and company != 'N/A'
GROUP BY hs.ticker, company, sector, year(day);

DROP TABLE if exists ticker_firstlastcloseyear;
CREATE TEMPORARY TABLE ticker_firstlastcloseyear
AS
SELECT first.ticker as ticker,
            company,
            sector,
            first.year as year,
            totvolume_ticker,
            firstclose_ticker,
            lastclose_ticker,
            totclose_ticker,
            totcount_ticker
FROM ( SELECT tfldy.ticker as ticker,
              company, sector, year, totvolume_ticker,
              hsp.close as firstclose_ticker,
              totclose_ticker, totcount_ticker
       FROM ticker_firstlastdateyear tfldy JOIN historical_stock_prices hsp
           ON (tfldy.ticker = hsp.ticker and tfldy.firstdate_ticker = hsp.day)
     ) first
JOIN ( SELECT tfldy.ticker as ticker,
                              year as year,
                              hsp.close as lastclose_ticker
            FROM ticker_firstlastdateyear tfldy JOIN historical_stock_prices
hsp
                 ON (tfldy.ticker = hsp.ticker and tfldy.lastdate_ticker =
hsp.day)
          ) last
ON (first.ticker = last.ticker and first.year = last.year);


DROP TABLE if exists company_quotationyear;
CREATE TEMPORARY TABLE company_quotationyear
AS
SELECT company,
            sector,
            year,
            totvolume_company,
            (((lastcloses_company - firstcloses_company) / firstcloses_company)
* 100) as delta_quot,
            (totclose_company / totcount_company) as avg_dailyquot
FROM ( SELECT company,
              sector,
              year,
              SUM(totvolume_ticker) as totvolume_company,
              SUM(firstclose_ticker) as firstcloses_company,
              SUM(lastclose_ticker) as lastcloses_company,
              SUM(totclose_ticker) as totclose_company,
              SUM(totcount_ticker) as totcount_company
            FROM ticker_firstlastcloseyear
            GROUP BY company, sector, year
          ) tmp;


DROP TABLE if exists ex2complex_hive;
CREATE TABLE ex2complex_hive
ROW FORMAT DELIMITED FIELDS TERMINATED by ','
AS
SELECT sector,
            year,
       cast(AVG(totvolume_company) as BIGINT) as avg_volume,
       ROUND(AVG(delta_quot), 2) as delta_quot,
       ROUND(AVG(avg_dailyquot), 2) as avg_dailyquot
FROM company_quotationyear
GROUP BY sector, year;
```

Figura 10: Hive Esercizio 2 Complex hql

```
HIVE EX3

DROP TABLE if exists ticker_firstlastdateyear;

CREATE TEMPORARY TABLE ticker_firstlastdateyear
AS
SELECT ticker,
            year(day) as year,
            MIN(day) as first_date,
            MAX(day) as last_date
FROM historical_stock_prices
WHERE year(day) between '2016' and '2018'
GROUP BY ticker, year(day);


---------- MAIN PERSONAL VERSION: ----------
---- quotation => sum first_close and sum last_close, then delta_quot ----
DROP TABLE if exists ticker_quotationyear;

CREATE TEMPORARY TABLE ticker_quotationyear
AS
SELECT first.ticker as ticker,
            first.year as year,
            firstclose_ticker,
            lastclose_ticker
FROM ( SELECT tfldy.ticker as ticker,
             tfldy.year as year,
             hsp.close as firstclose_ticker
      FROM ticker_firstlastdateyear tfldy JOIN historical_stock_prices hsp
            ON (tfldy.ticker = hsp.ticker and tfldy.first_date = hsp.day)
     ) first
JOIN ( SELECT tfldy.ticker as ticker,
              tfldy.year as year,
              hsp.close as lastclose_ticker
      FROM ticker_firstlastdateyear tfldy JOIN historical_stock_prices hsp
                ON (tfldy.ticker = hsp.ticker and tfldy.last_date = hsp.day)
     ) last
ON (first.ticker = last.ticker and first.year = last.year);


DROP TABLE if exists company_quotationyear;

CREATE TEMPORARY TABLE company_quotationyear
AS
SELECT company,
       COLLECT_SET( CONCAT( cast(year as STRING), ":",
       cast(cast(((lastcloses_company - firstcloses_company)/
                  firstcloses_company)*100 as BIGINT)
                  as STRING), "%")) as quot_years
FROM (
       SELECT company, year,
              SUM(firstclose_ticker) as firstcloses_company,
              SUM(lastclose_ticker) as lastcloses_company
       FROM historical_stocks hs JOIN ticker_quotationyear tqy
            ON hs.ticker = tqy.ticker
       GROUP BY company, year
     ) tmp
GROUP BY company;


DROP TABLE if exists ex3_hive;

CREATE TABLE ex3_hive
ROW FORMAT DELIMITED FIELDS TERMINATED by ','
AS
SELECT CONCAT ("{", CONCAT_WS(';', comp_list), "}") as companies,
            quot_years
FROM ( SELECT COLLECT_SET(company) as comp_list,
              quot_years
       FROM ( SELECT company,
                     CONCAT_WS(';', quot_years) as quot_years
              FROM company_quotationyear
              WHERE size(quot_years)==3
            ) comp_totquot
       GROUP BY quot_years
      ex3_hive_tot
WHERE size(comp_list)>1
ORDER BY size(comp_list) desc;
```

Figura 11: Hive Esercizio 3 Main hql

```
SET threshold = 5;

DROP TABLE if exists ticker_firstlastdateyear;
CREATE TEMPORARY TABLE ticker_firstlastdateyear
AS SELECT ticker, year(day) as year, MIN(day) as first_date, MAX(day) as last_date
FROM historical_stock_prices
WHERE year(day) between '2016' and '2018'
GROUP BY ticker, year(day);

DROP TABLE if exists ticker_quotationyear;
CREATE TEMPORARY TABLE ticker_quotationyear
AS SELECT first.ticker as ticker, first.year as year,
       cast(((last.last_close - first.first_close)/first.first_close)*100 as BIGINT) as delta_quot
FROM ( SELECT tfldy.ticker as ticker, tfldy.year as year, hsp.close as first_close
       FROM ticker_firstlastdateyear tfldy JOIN historical_stock_prices hsp
            ON (tfldy.ticker = hsp.ticker and tfldy.first_date = hsp.day) ) first
JOIN ( SELECT tfldy.ticker as ticker, tfldy.year as year, hsp.close as last_close
       FROM ticker_firstlastdateyear tfldy JOIN historical_stock_prices hsp
            ON (tfldy.ticker = hsp.ticker and tfldy.last_date = hsp.day)  ) last
ON (first.ticker = last.ticker and first.year = last.year);

DROP TABLE if exists company_quotationyear;
CREATE TEMPORARY TABLE company_quotationyear
AS SELECT company, year, cast (AVG(delta_quot) as INT) as delta_quot
FROM historical_stocks hs JOIN ticker_quotationyear tqy
     ON hs.ticker = tqy.ticker
GROUP BY company, year;

DROP TABLE if exists ex3_hive_SameQuots;
CREATE TEMPORARY TABLE ex3_hive_SameQuots
AS SELECT companies,
       CONCAT( "2016", ":", cast(tmp.quot2016 as STRING), "%",
               ";", "2017", ":", cast(tmp.quot2017 as STRING), "%",
               ";", "2018", ":", cast(tmp.quot2018 as STRING), "%") as deltaQuot
FROM ( SELECT CONCAT ("{", CONCAT_WS(';', COLLECT_SET(c1.company)), "}") as companies,
              c1.delta_quot as quot2016, c2.delta_quot as quot2017, c3.delta_quot as quot2018
       FROM company_quotationyear c1 JOIN company_quotationyear c2
                 ON (c1.company = c2.company and c1.year != c2.year)
                                  JOIN company_quotationyear c3
                 ON (c1.company = c3.company and c1.year != c3.year and c2.year != c3.year)
       WHERE c1.year = '2016' and c2.year = '2017' and c3.year = '2018'
       GROUP BY c1.delta_quot, c2.delta_quot, c3.delta_quot
       HAVING count(*) > 1 ) tmp;

DROP TABLE if exists ex3_hive_Singles;
CREATE TEMPORARY TABLE ex3_hive_Singles
AS SELECT cast(tmp.companies as STRING) as company,
       tmp.quot2016 as quot2016, tmp.quot2017 as quot2017, tmp.quot2018 as quot2018
FROM ( SELECT CONCAT_WS(';', COLLECT_SET(c1.company)) as companies,
              c1.delta_quot as quot2016, c2.delta_quot as quot2017, c3.delta_quot as quot2018
       FROM company_quotationyear c1 JOIN company_quotationyear c2
                 ON (c1.company = c2.company and c1.year != c2.year)
                                  JOIN company_quotationyear c3
                 ON (c1.company = c3.company and c1.year != c3.year and c2.year != c3.year)
       WHERE c1.year = '2016' and c2.year = '2017' and c3.year = '2018'
       GROUP BY c1.delta_quot, c2.delta_quot, c3.delta_quot
       HAVING count(*) == 1 ) tmp;

DROP TABLE if exists ex3_hive_SimilQuots_tmp;
CREATE TEMPORARY TABLE ex3_hive_SimilQuots_tmp
AS SELECT t1.company as comp1, t2.company as comp2
FROM ex3_hive_Singles t1 JOIN ex3_hive_Singles t2
     ON ( SQRT(pow((t1.quot2016-t2.quot2016),2)  +
               pow((t1.quot2017-t2.quot2017),2) +
               pow((t1.quot2018-t2.quot2018),2)) = '${hiveconf:threshold}'
     or   SQRT(pow((t1.quot2016-t2.quot2016),2)  +
               pow((t1.quot2017-t2.quot2017),2) +
               pow((t1.quot2018-t2.quot2018),2)) = '0')
ORDER BY comp1,comp2;

DROP TABLE if exists ex3_hive_SimilQuots;
CREATE TEMPORARY TABLE ex3_hive_SimilQuots
AS SELECT DISTINCT CONCAT ("{", CONCAT_WS(';', temp.companies, "}")) as companies,
                   CONCAT ("similarity = ", cast('${hiveconf:threshold}' as STRING)) as similQuot
FROM ( SELECT tmp.comp1 as company, COLLECT_SET(tmp.comp2) as companies
       FROM ex3_hive_SimilQuots_tmp tmp
       GROUP BY tmp.comp1
       HAVING count(*) > 2 ) temp;

DROP TABLE if exists ex3_hive;
CREATE TABLE ex3_hive
ROW FORMAT DELIMITED FIELDS TERMINATED by ','
AS SELECT *
FROM ex3_hive_SameQuots
UNION
SELECT *
FROM ex3_hive_SimilQuots;
```

Figura 12: Hive Esercizio 3 Facoltativo hql

5 Implementazione

In questa Sezione sono presentate più nel dettaglio le scelte implementative adottate durante lo sviluppo dei vari Job nelle varie tecnologie. In Sezione 5.1 si illustrano le decisioni comuni ai vari esercizi. In Sezione 5.2, 5.3 e 5.4 ci si focalizza sulle principali implementazioni degli esercizi, rispettivamente in Hadoop, Hive e Spark. Tali Sezioni fanno riferimento al codice del progetto, qui non inserito per ragioni di spazio e fornito direttamente in allegato a questa relazione, con opportuni commenti.

5.1 Scelte generali

Di seguito sono descritte alcune scelte implementative generali, prese sulla base delle osservazioni effettuate in fase di analisi e progettazione.

- Ogni job è stato progettato per funzionare individualmente e a prescindere da una eventuale pre-pulizia dei dati. In una fase successiva si è considerata la possibilità di aumentare l'efficienza dei vari job, spostando l'operazione di pulizia e filtraggio dei dati a monte dell'elaborazione e fornendo in input ai job direttamente dei dati puliti. Questa scelta è stata implementata e ha portato a dei risultati leggermente positivi nel Job1 e Job2, con diminuzione dei tempi di esecuzione tra il 5% ed il 10%, ma sempre sotto i 2 secondi di guadagno. Nel Job3, al contrario, portava a dei risultati differenti, in quanto la pulizia dei dati di HS svolta specificatamente per il Job3 considerava soltanto i campi per esso rilevanti, ovvero "ticker" e "company", mentre la pulizia dei dati generalizzata considerava anche il campo "sector". Questo ha portato a un pruning di valori maggiore, incorretto per il Job3, in quanto esso necessita dei soli campi "ticker" e "company", e il risparmio di pochi secondi non compensa la perdita di dati utili e rilevanti per l'analisi richiesta. Una pulizia dei dati a monte ad-hoc per ogni Job è stata ritenuta superflua, oltre che potenzialmente penalizzante nel caso in cui non fosse richiesto di eseguire più volte lo stesso Job sullo stesso input.

- Si è costruita una classe *Utility* per metodi di supporto presenti in uno o più Job, come il metodo *inputExist(String s)* che verifica l'esistenza della stringa passata, per controllare se un campo dei record fosse presente ma vuoto. Nello stesso package *utilities* sono inoltre presenti le classi per la pulizia a monte dei dati sopra menzionata, qualora la si volesse utilizzare.

- Per la separazione dei record presenti in HS è stato necessario utilizzare l'espressione regolare ,(? = ([^\"] ∗ \"[^\"] ∗ \") ∗ [^\"] ∗ $) in quanto, da un'analisi del dataset, si è riscontrato che in alcuni campi "company" fosse presente una virgola che avrebbe portato a suddividere in più campi la riga, facendo erroneamente risultare il dato come sporco. Fortunatamente, in presenza delle virgole all'interno del campo, il campo stesso viene delimitato da delle virgolette, che permettono la corretta identificazione del dato utilizzando tale regex all'interno dello split.

- Si è preferito utilizzare, come risultati intermedi delle varie elaborazioni dei job, dei campi in formato Text sui quali viene eseguito il parsing all'inizio di ogni fase. Questo ha permesso di mantenere bassa la complessità generale del progetto, evitando di dover scrivere numerose classi per oggetti intermedi che, tra l'altro, avrebbero occupato maggiore spazio.

- I file in output sono stati forniti senza alcuna particolare formattazione per facilitare la conversione a seconda dell'utilizzo che se ne debba fare: si è comunque prediletta una formattazione dei dati comoda per una divisione nel tipico formato .CSV, usando la virgola come carattere separatore. Inoltre, nelle tecnologie Hadoop e Spark, per ogni Job viene inserito in testa al file di output un'intestazione esplicativa dei valori delle colonne.

- La procedura di join, richiesta per lo svolgimento del secondo e del terzo esercizio, è stata realizzata in Hadoop mediante *Reduce Side Join*: si sfrutta lo *shuffle & sort* per aggregare i risultati in uscita dai Mapper e si impiegano separatori personalizzati che permettono, lato Reducer, di distinguere il Mapper di provenienza per ciascun Text nell'Iterable.

5.2 Hadoop

ESERCIZIO 1
Questo esercizio presenta una sola implementazione in quanto non sono state trovate distinte interpretazioni da sviluppare. Consiste in un singolo job e comprende un solo Mapper (*Ex1Mapper*) e un solo Reducer (*Ex1Reducer*).
Ex1Mapper si occupa di prendere i dati da HSP, controllare che i campi delle varie righe non siano nulli o di un formato non idoneo e controllare che siano all'interno dell'intervallo temporale richiesto. Fornisce in ouput la data, il valore di close e il volume associati a ogni ticker.
Ex1Reducer prende in input i valori passati da *Ex1Mapper* ed esegue le seguenti elaborazioni:

- calcola la variazione percentuale della quotazione, andando a ricavare quanto valga il "ticker" all'inizio del periodo temporale e quanto valga alla fine.
- calcola la media del volume del ticker, andando a sommare tutti i valori "volume" di ogni ticker e dividendo per il numero di record incontrati.
- calcola il minimo e il massimo "close" registrati nel periodo di interesse.

In output restituisce come chiave "ticker" e come value i valori sopraindicati, ordinando le righe per variazione percentuale decrescente. Si è scelto di utilizzare una classe ad-hoc per rappresentare i risultati del Job1 *Result_Ex1* nel package *utilities*, che implementa Comparable e che verrà impiegata anche dal Job1 di Spark.
Non è stato inserito un Combiner in quanto avrebbe richiesto un refactoring delle implementazioni di *Ex1Mapper* e *Ex1Reducer* e non è stato ritenuto significativo il suo sviluppo, potendo già osservare la differenza di prestazioni utilizzando o meno un Combiner nel Job2.

ESERCIZIO 2
Questo esercizio si è presentato come il più complesso da svolgere in quanto sono state elaborate diverse interpretazioni. La discussione ora viene suddivisa descrivendo nel dettaglio:

- *Ex2_basic* versione nella quale vengono considerati solo "ticker" e "settore".
- *Ex2_complex* versione nella quale vengono considerati "ticker","company" e "sector", a sua volta distinta in:
  - *Ex2_Companies* versione che non prevede l'utilizzo di Combiner.
  - *Ex2_Companies_Combiner* versione che sfrutta due Combiner.

Esercizio 2 Basic. Questa è la versione corrispondente all'interpretazione più semplice dei dati. Come anticipato in Sezione 2, qui il campo "company" di HS non viene preso in considerazione e questo permette di avere uno step di MapReduce in meno. Consiste in due job in chain e comprende tre Mapper differenti:

- *Ex2HSMapper*
- *Ex2HSPMapper*
- *Ex2Mapper*

e due Reducer:

- *Ex2JoinReducer*
- *Ex2Reducer*

Di seguito è fornita una panoramica del suo funzionamento.

1. I Mapper *Ex2HSMapper* e *Ex2HSPMapper* costituiscono il punto di partenza del Job, incaricati di prendere i dati dai rispettivi dataset, verificarne la correttezza in termini di validazione del tipo di dato ed appartenenza all'intervallo corretto, e che in seguito estraggono i dati rilevanti per il job.

2. L'output di entrambi i primi Mapper viene dunque dato in input a *Ex2JoinReducer*. Questo ottiene sia i dati rilevanti appartenenti ad HS che ad HSP, unificati grazie alla chiave "ticker" e distinti gli uni dagli altri grazie all'utilizzo degli appositi separatori inseriti. In questa fase vengono aggregati i valori dei due dataset per calcolare, per ogni anno e ticker, quale sia il valore iniziale e finale del ticker, oltre al volume annuale, la somma delle close annuali e il numero di giorni dell'anno in cui si registrano record riguardanti il ticker. Per raggiungere tale scopo sono state utilizzate delle mappe, come in altre parti del progetto, evitando la creazione di tipi di dati appositi al fine di aumentare la leggibilità del programma e diminuire la quantità di

codice introdotto. Alla fine del reducer si calcola la variazione annuale del ticker usando i valori del ticker stesso a inizio e fine anno, per poi cambiare la chiave in settore-anno e aggregare di conseguenza.

3. *Ex2Mapper* prende le righe prodotte da *Ex2JoinReducer* ed esegue un mapping unitario, in quanto la chiave settore-anno viene già definita nello step precedente.

4. Infine *Ex2Reducer* si occupa di aggregare i valori per settore e anno andando a sommare tutti i volumi dei ticker, le variazioni percentuali annuali e andandole a dividere per il numero di ticker nel settore. Viene calcolato anche quanto valga in media un ticker del settore, andando a sommare tutte le close di tutti i ticker del settore e a dividere tale valore per la somma del numero di record registrati per tutti i ticker del settore.
   In uscita da *Ex2Reducer* si ha il risultato finale, che viene ordinato per settore e anno.

Esercizio 2 Complex. Questa versione del Job2 è più complessa rispetto alla precedente poiché, considerando anche il campo "company", necessita di un'ulteriore elaborazione e di conseguenza di un'ulteriore fase MapReduce. Consiste in tre job in chain e vengono impiegati quattro Mapper:

- *Ex2HSPMapper*
- *Ex2HSMapper_Companies*
- *Ex2CompanyMapper_Companies*
- *Ex2SectorMapper_Companies*

e tre Reducer:

- *Ex2JoinReducer_Companies*
- *Ex2CompanyReducer_Companies*
- *Ex2SectorReducer_Companies*

Di seguito è fornita una panoramica del suo funzionamento.

1. *Ex2HSPMapper* è lo stesso usato per la versione *Basic* in quanto i campi di HSP necessari restano invariati. *Ex2HSMapper_Companies* è un Mapper molto simile al Mapper per HS usato nella versione precedente, ma che include tra i dati rilevanti estratti anche "company".

2. I record estratti dai due precedenti Mapper vengono riuniti da *Ex2JoinReducer_Companies* con una logica uguale alla versione *Basic* dove le uniche differenze sono l'aggiunta della gestione del campo "company" e rimandare il calcolo della variazione percentuale al successivo Reducer.

3. *Ex2CompanyMapper_Companies* è il Mapper unitario incaricato di gestire i record con chiave "company" e "year", anche se questa viene già impostata dal reducer precedente.

4. *Ex2CompanyReducer_Companies* rappresenta la vera differenza rispetto alla precedente versione, in quanto consente di calcolare il valore iniziale e finale dell'azienda nel suo complesso, sommando i valori iniziali e finali dei ticker della stessa. Inoltre calcola la media del valore di un ticker dell'azienda andando a sommare tutte le close dei ticker e dividendo per la somma del numero di record di ogni ticker.

5. *Ex2SectorMapper_Companies* è il Mapper unitario incaricato di gestire i record con chiave "sector" e "year", già impostata dal precedente Reducer.

6. *Ex2SectorReducer_Companies* è l'ultimo Reducer di questo Job, incaricato di aggregare i valori per settore e anno: esso calcola la media del volume delle aziende del settore, la media delle variazioni percentuali del settore e la media del valore medio dei ticker nelle aziende del settore.
   In uscita da *Ex2SectorReducer_Companies* si ha il risultato finale, che viene ordinato per settore e anno.

Esercizio 2 Complex with Combiner è l'ultima versione del Job2 sviluppata. Presenta le stesse elaborazioni della precedente, andando però ad aggiungere due Combiner per verificarne l'impatto sulle prestazioni:

- *Ex2CombinerCompany_withCompany*
- *Ex2CombinerSector_withCompany*

Ex2CombinerCompany_withCompany si occupa di aggregare i dati prima di *Ex2CompanyReducer_Companies*, senza effettuare le operazioni di calcolo della variazione percentuale dell'azienda e calcolo della media delle close dei ticker dell'azienda.
Ex2CombinerSector_withCompany si occupa di aggregare i dati prima di *Ex2SectorReducer_Companies*, senza effettuare il calcolo delle medie dei valori finali.

ESERCIZIO 3
Questo esercizio presenta in Hadoop una sola implementazione. Poiché richiede di calcolare i trend delle aziende tra 2016 e 2018 ed aggregarle rispetto all'uguaglianza di tali trend, necessita dell'impiego di un join tra HSP e HS (similmente all'Esercizio 2).
Consiste in due job in chain e comprende 3 Mapper differenti:

- *Ex3HSMapper*
- *Ex3HSPMapper*
- *Ex3Mapper*

e due Reducer:

- *Ex3JoinReducer*
- *Ex3Reducer*

I Mapper *Ex2HSMapper* e *Ex2HSPMapper* sono impiegati per verificare la correttezza e la validità dei dati in input, nonché per estrarre i campi rilevanti.
Similmente al caso precedente, il join è un *Reduce Side Join* e fa uso di separatori personalizzati per distinguere i dati provenienti dai due Mapper. Tuttavia *Ex3JoinReducer* è stato implementato con un approccio differente dal suo corrispondente nel Job 2: tale variazione è stata adottata per fornire maggiore eterogeneità tra le strategie implementative impiegate e per risparmiare, come vedremo, un intero step MapReduce. Nello specifico:

1. *Ex3JoinReducer* comprende una classe privata *Pair*, che definisce una coppia <String,Integer>utile per i passi seguenti;
2. il metodo *setup* di Reducer inizializza 3 mappe, definite come variabili d'istanza e che avranno il compito di memorizzare i risultati al termine del metodo *reduce*; tali mappe conterranno, rispettivamente, la quotazione iniziale, finale e la variazione di quotazione di ciascuna azienda in ogni anno;
3. nel *reduce* si calcolano anzitutto, per il singolo ticker e per ciascun anno, le date iniziali e finali in cui esso compare e i valori di close loro associati; si ricava inoltre dal join il nome dell'azienda cui appartiene l'azione corrente.
4. a questo punto si aggiornano le due mappe della quotazione finale e iniziale delle aziende con i corrispettivi valori ricavati dalla corrente iterazione del reduce, eventualmente sommati ai precedenti se presenti;
5. l'implementazione qui scelta prevede di impiegare metodo il *cleanup* del Reducer per effettuare alcune operazioni al termine del *reduce*: difatti tale metodo è eseguito al termine di tutte le iterazioni del *reduce*, dunque le mappe prima discusse contengono ora i valori complessivi di quotazione iniziale e finale di ciascuna azienda negli anni 2016-2018. Ciò permette di evitare un ulteriore step MapReduce, poiché si calcola la variazione di quotazione di ciascuna azienda nei tre anni direttamente nel *cleanup*, si concatenano i risultati come stringa e infine si forniscono in output.

Ex3Mapper ed *Ex3Reducer* sono utilizzati per raggruppare tutte le aziende caratterizzate dal medesimo trend. Per fare ciò, *Ex3Mapper* rende la stringa, identificante il trend nei tre anni, chiave e azienda valore: in tal modo si sfrutta lo *shuffle* & *sort* per raggruppare le aziende rispetto ai trend. Infine, *Ex3Reducer* nel *reduce* verifica che il numero di aziende con un certo trend sia superiore a 1, ovvero che siano state trovate almeno due aziende con stesse variazioni di quotazione, nel qual caso le memorizza in una mappa inizializzata nel *setup*; il *cleanup* ordina tale mappa rispetto al numero di aziende (mediante un metodo della classe *Utilities*) e fornisce in output il trend in comune, il set di aziende con tale trend e il loro numero (utile per effettuare confronti tra diverse implementazioni, come discusso in Sezione 6).

5.3 Hive

INITIALIZATION
Prima di presentare le scelte implementative adottate in ciascun esercizio, facciamo qui riferimento al file *init_hive.hql*, contenente l'hql per caricare i dataset del progetto nelle tabelle corrispondenti *historical_stock_prices* e *historical_stocks*. In particolare, si evidenzia come anche in Hive sia stato necessario tenere in considerazione che alcuni record di HS presentassero il nome dell'azienda tra "" e con una virgola all'interno. Dovendo mantenere come *field delimiter* la virgola, a causa della struttura dei dati in input, e per evitare che ciò comportasse uno split non corretto dei nomi dell'azienda, si è scelto come *row format* di *historical_stocks* la libreria di Hadoop API SerDe: essa ha permesso di definire il comportamento corretto da adottare nella situazione di cui sopra, ovvero il riconoscimento della virgola come parte del nome dell'azienda, senza necessità di un pre-processamento personalizzato dei record.

ESERCIZIO 1
In Hive sono state implementate tre versioni del primo esercizio:

- *ex1_hive_main.hql*, la versione principale, descritta di seguito.
- *ex1_hive_altern.hql*, con la stessa logica di *ex1_hive_main.hql* ma caratterizzata da un maggior numero di temporary tables: è stata sviluppata per poter verificare gli effetti dell'impiego di tabelle temporanee sulle performance.
- *ex1_hive_res.hql*, analoga a *ex1_hive_main.hql* ma con miglior formato output, utilizzato per produrre i risultati presentati nella relazione.

Di seguito è fornita una panoramica del funzionamento di *ex1_hive_main.hql*.

1. Viene creata la tabella temporanea *ticker_firstlastvalues*: essa memorizza, per ciascun ticker in *historical_stock_prices* compreso tra il 2008 e il 2018, la prima e l'ultima data di comparsa, il valore di close minimo e massimo e il volume medio.

2. Ora si procede a ricavare, mediante join tra *ticker_firstlastvalues* e *historical_stock_prices*, la first_close e la last_close, ovvero, rispettivamente, la close in corrispondenza della prima e l'ultima data per quel ticker; si noti che il join sia eseguito con *historical_stock_prices* come secondo membro, poiché di dimensione maggiore (tale aspetto è presente in tutte le implementazioni e non sarà menzionato nuovamente).

3. Infine si crea la tabella *ex1_hive* e vi si memorizzano, per ciascun ticker, il volume medio, la close minima e massima e la variazione di quotazione, calcolata come da definizione e arrotondata: i record sono ordinati rispetto a tale variazione in modo decrescente.

ESERCIZIO 2
In Hive sono state implementate due versioni del secondo esercizio:

- *ex2basic_hive.hql*, che non tiene conto delle aziende per il calcolo dei trend dei settori.
- *ex2complex_hive.hql*, che invece considera sia ticker che aziende.

Di seguito è fornita una panoramica del funzionamento di *ex2basic_hive.hql*.

1. Viene creata la tabella temporanea *ticker_sector*, che memorizza il nome del settore, il volume, la close e il giorno per ogni occorrenza di ciascun ticker, a partire dal join tra *historical_stock_prices* e *historical_stocks*, e limitato al solo periodo compreso tra il 2008 e il 2018; si noti come occorra filtrare i record con settore nullo per garantire il corretto output del job.

2. Viene creata la tabella temporanea *ticker_sector_year*, su cui sono salvati, per ciascun ticker e anno, la somma dei volumi del ticker, la somma delle close, la prima data di comparsa e l'ultima, e infine il numero di occorrenze, necessarie per il calcolo della quotazione giornaliera media.

3. Ora, con un approccio simile a *ex1_hive_main.hql*, si ricavano le close iniziali e finali del ticker, a partire dai join di *ticker_sector_year* con *ticker_sector*: infine si ricavano, a partire dalle definizioni fornite nelle specifiche progettuali, per ciascun settore, il volume annuale medio, la variazione di quotazione annuale media e la quotazione giornaliera media in quell'anno. Come si può osservare, abbiamo qui ragionato solo in termini di ticker e settori, non considerando le aziende.

Di seguito è fornita una panoramica del funzionamento di *ex2complex_hive.hql*.

1. Viene creata la tabella temporanea *ticker_firstlastdateyear*, che memorizza, a partire dal join tra *historical_stock_prices* e *historical_stocks*, per ogni ticker in un dato anno compreso tra 2008 e 2018, i nomi di compagnia e settore, la somma dei volumi, prima e ultima data di comparsa, la somma delle close e il numero di occorrenze.

2. Viene creata la tabella temporanea *ticker_firstlastcloseyear* in cui, similmente a *ex2basic_hive.hql*, si ottengono i valori di close iniziali e finali per ciascun ticker in quell'anno.

3. Sono calcolati, per ogni azienda in ogni anno, la somma dei volumi, delle close iniziali e finali, dei close totali e del numero complessivo di occorrenze, a partire dalle informazioni sopra ottenute per i vari ticker; è creata la tabella temporanea *company_quotationyear*, che memorizza, per ciascuna azienda in ogni anno, il volume totale precedentemente ottenuto, la variazione di quotazione annuale dell'azienda e la sua quotazione giornaliera media.

4. Come si è osservato, in *ex2complex_hive.hql* si ricavano le informazioni sui settori a partire da quelle delle aziende. Infine si memorizzano nella tabella conclusiva i valori medi, per un settore in un anno, di volume, variazione di quotazione e quotazione giornaliera.

ESERCIZIO 3
In Hive sono state implementate quattro versioni del terzo esercizio:
- *ex3_hive_main.hql*, la versione principale, descritta di seguito: essa interpreta la variazione di quotazione annuale di un'azienda come la differenza percentuale tra le close finali totali e iniziali dei ticker di quell'azienda in quell'anno.
- *ex3_hive_altern.hql*, che interpreta la variazione di quotazione annuale di un'azienda come la media delle variazioni di quotazione dei ticker di quell'azienda in quell'anno.
- *ex3_hive_res.hql*, analoga a *ex3_hive_main.hql* ma con miglior formato output, tra cui il numero di aziende con un certo trend, utilizzato per produrre i risultati presentati nella relazione.
- *ex3_hive_facoltativo.hql*, simile a *ex1_hive_main.hql* ma che tiene conto, per le aziende con trend non equivalente ad altri, di un tentativo di aggregazione basata su somiglianza tra trend (definita mediante distanza euclidea tra i trend di due aziende nei tre anni in questione).

Di seguito è fornita una panoramica del funzionamento di *ex3_hive_main.hql*.

1. Viene creata la tabella temporanea *ticker_firstlastdateyear*, in cui si memorizza, a partire da *historical_stock_prices*, per ciascun ticker negli anni compresi tra 2016 e 2018, la prima e ultima data di comparsa del ticker in quell'anno.

2. Viene creata la tabella temporanea *ticker_quotationyear*, in cui si memorizza, per ciascun ticker e anno, le close iniziali e finali, ottenute a partire dal join di *ticker_firstlastdateyear* con *historical_stock_prices*

3. Dal join di *ticker_quotationyear* con *historical_stocks* si ricavano, per ciascuna azienda in un anno, le close iniziali e finali, definite come somme, rispettivamente, delle close iniziali e finali dei ticker appartenenti a quell'azienda

4. Viene creata la tabella temporanea *company_quotationyear*, che memorizza, per ogni azienda, il set contenente i trend di quell'azienda nei tre anni 2016, 2017 e 2018.

5. Infine si converte tale set in una stringa e si effettua una *collect* rispetto ad essa, di modo da ottenere tutte le aziende con medesimo trend in tutti e tre gli anni. Nella tabella conclusiva *ex3_hive* si memorizza la stringa ottenuta da tale *collect* e il trend delle aziende in essa presenti: i risultati sono filtrati affinché siano presenti solo insiemi di aziende superiori a 1 con un certo trend comune, e sono ordinati in modo decrescente rispetto a tale valore. Nella versione *ex3_hive_res.hql* tale numero è anche parte dell'output finale.

Infine, alcune osservazioni su *ex3_hive_facoltativo.hql*.

- La differenza rispetto a *ex3_hive_main.hql* consiste nel fatto che si distinguano i gruppi di aziende con trend equivalente da quelli di aziende con trend simile. Per calcolare la similarità tra due trend, si considera la distanza euclidea su tre coordinate (corrispondenti alle variazioni di quotazione nei tre anni) e si raggruppano inizialmente le aziende a coppie nel caso in cui il valore di similarità tra i trend sia pari a un certo *threshold* modificabile.

- Una volta definito il valore di similarità, si procede in maniera analoga al caso precedente, aggregando le aziende con stessa similarità rispetto a ogni azienda e rimuovendo i duplicati; infine si uniscono i risultati ottenuti dalla ricerca di equivalenza tra trend e quelli ricavati dalla ricerca di similarità.

5.4 Spark

Nello svolgimento dei vari Job in Spark sono state utilizzate costantemente le strutture dati "Tuple" in quanto hanno permesso di modellare agilmente i vari risultati intermedi senza la necessità di dover creare dei tipi di dato appositi o di dover utilizzare dei campi testuali sui quali dover fare una pre-elaborazione di Parsing.

ESERCIZIO 1
L'implementazione del Job 1 in Spark non presenta varianti. Sono state implementate diverse *Lambda Expressions* personalizzate, descritte nel seguito:

- *checkLine*, è una funzione di filtraggio, viene utilizzata per rimuovere le righe associate a dati sporchi o ad una data esterna all'intervallo richiesto.
- *prepareValues*, è un'operazione di mapping, utilizzata solo per replicare i valori date e close in una struttura "Tuple" con il corretto numero di campi, adatta all'elaborazione richiesta dal reducer successivo.
- *reducer*, si occupa di trovare la prima e l'ultima data utile di ogni ticker ed il valore di close ad esse associato, oltre a trovare i valori minimi e massimi di close ed il volume totale.
- *produceResults*, è un mapper incaricato di effettuare le aggregazioni richieste per calcolare la variazione percentuale del ticker ed il volume medio, producendo in uscita un'istanza Comparable di "Result_Ex1", al fine di poter ordinare i risultati.

ESERCIZIO 2
Questo esercizio è stato presentato in due versioni:

- *Ex2_spark_distributedRow*
- *Ex2_spark_singleRow*

Le due versioni utilizzano le stesse funzioni ed implementano entrambe il corrispettivo della versione Complex implementata in Hadoop e Hive, ma si differenziano per l'utilizzo di risultati intermedi inseriti nello heap delle variabili. Questo sarà rilevante ai soli fini dello studio della differenza di performance tra le due varianti e per la quale si rimanda alla sezione 7.
Le funzioni che vengono utilizzate sono le seguenti.

- *checkInputHSP*, è una funzione di filtraggio, viene utilizzata per rimuovere le righe associate a dati sporchi o ad una data esterna all'intervallo richiesto.
- *checkInputHS*, come la precedente, si occupa del filtraggio di righe associate a dati sporchi.
- *prepareValuesHS*, mappa i dati in ingresso di HS, prelevando quelli rilevanti per il job.
- *prepareValuesHSP*, come la precedente, per HSP.
- *reorganizeValuesAfterJoin*, viene utilizzata subito dopo aver eseguito il join dei valori prelevati da HS e HSP, per preparare i valori per il successivo reducer, infine imposta come chiave (ticker,anno).

- *reduce_sumVolumeTicker_findFirstLastClose*, vengono effettuate le prime aggregazoini di dati ovvero:
  - somma di tutte le close
  - trovare i primi valori delle close di ogni ticker e anno
- *map_fromTickerToCompany*, si occupa soltanto del cambio di chiave da (ticker,anno) a (compagnia,anno).
- *reduce_sumVolumeCompany_sumFirstLastCloseCompany_sumCloseSumCounterCompany*, si occupa di alcune aggregazioni:
  - somma dei volumi;
  - somma dei primi valori dei close;
  - somma degli ultimi valori dei close;
  - somma di tutte le close;
  - somma del numero di record di ogni ticker.
- *map_varYearCompany_dailyQuotCompany_fromCompanyToSector* si occupa di calcolare la variazione percentuale e il valore medio della quotazione giornaliera dell'azienda. In seguito cambia la chiave in (settore,anno).
- *reduce_sumVolumes_sumVars_sumQuots* si occupa di sommare volumi, variazioni e quotazioni, oltre a contare quante aziende ci siano nel settore.
- *map_avgSector* calcola i risultati finali dividendo le somme precedentemente calcolate per il numero di aziende.

ESERCIZIO 3

L'implementazione di questo esercizio non presenta varianti, è stata implementata senza produrre risultati intermedi e utilizza le seguenti funzioni.

- *checkInputHS*, filtra righe con valori sporchi.
- *checkInputHSP*, è una funzione di filtraggio, viene utilizzata per rimuovere le righe associate a dati sporchi o ad una data all'esterno dell'intervallo richiesto.
- *prepareValuesHS*, mappa i dati in ingresso di HS, prelevando quelli rilevanti al job.
- *prepareValuesHSP*, come la precedente, per HSP.
- *reorganizeValuesAfterJoin* viene chiamata subito dopo aver eseguito il join tra i valori di HS e HSP, ed è utilizzata per replicare alcuni valori al fine di prepararli ad un'elaborazione effettuata nel reducer successivo, impostando come chiave (ticker, anno).
- *reduce_findFirstLastCloses* si occupa di trovare i valori iniziali e finali delle close di ogni ticker di ogni anno.
- *map_fromTickerToCompany* effettua un mapping cambiando la chiave a (ticker,anno) a (compagnia,anno).
- *reduce_sumFirstLastCloses* somma i rispettivi valori di close iniziali e finali per ogni azienda, al fine di calcolare quanto valga l'azienda ad inizio e fine di ogni anno.
- *map_calculateVarPercCompanyYear_changeKeyToCompany* calcola la variazione percentuale annua di ogni azienda, cambia la chiave ad azienda ed inserisce il valore calcolato nell'anno cui si riferisce.
- *reduce_unifyTrends* unisce le variazioni percentuali di anni differenti della stessa azienda.
- *checkAllYearPresent* costituisce un'operazione di filtraggio, nella quale si controlla che siano stati calcolate le variazioni percentuali di tutte e tre gli anni.
- *invertKey_fromCompany_toVarYear* cambia la chiave da compagnia a trend, dove il trend è l'insieme delle variazioni percentuali per gli anni 2016,2017 e 2018.
- *reduce_companySameTrend* aggrega tutte le aziende con lo stesso trend.
- *mapByNumberSimilarCompaniesTrend* calcola quante siano le aziende con lo stesso trend e cambia la chiave da trend a numero di similarità, così da poter fornire un ordinamento decrescente per numero di similarità.

6 Presentazione Risultati

In questa Sezione sono illustrati i primi record appartenenti ai risultati delle esecuzioni nelle tre tecnologie. L'obiettivo è mostrare l'equivalenza dei record e del formato in output. In Hadoop e Spark il primo record descrive i campi corrispondenti a ciascuna colonna. I risultati delle versioni implementate sono visibili nella cartella *resultsFirst10* del progetto.

HADOOP EX1

```
TICKER,VARIAZIONE_QUOTAZIONE_%,PREZZO_MIN,PREZZO_MAX,VOLUME_MEDIO
EAF       267757%,0.002,22.37,1245139
ORGS      217416%,0.00314,19.8,8570
PUB       179900%,0.009,135.0,34449
RMP       121082%,0.03,78.54985,120487
CTZ       120300%,0.005,26.73,52050
CCD       111250%,0.015,25.55,105416
SAB       110429%,1.3985,318800.0,1695378
KE        99400%,0.015,22.2,73249
LN        96700%,0.015,49.63,394344
GHG       64850%,0.005,24.31,607659
```

HIVE EX1

```
EAF,267757%,0.002,22.37,1245139
ORGS,217416%,0.00314,19.8,8570
PUB,179900%,0.009,135.0,34449
RMP,121082%,0.03,78.54985,120487
CTZ,120300%,0.005,26.73,52050
CCD,111250%,0.015,25.55,105416
SAB,110429%,1.3985,318800.0,1695378
KE,99400%,0.015,22.2,73249
LN,96700%,0.015,49.63,394344
GHG,64850%,0.005,24.31,607659
```

SPARK EX1

```
TICKER,VARIAZIONE_QUOTAZIONE_%,PREZZO_MIN,PREZZO_MAX,VOLUME_MEDIO
EAF,267757%,0.002,22.37,1245139
ORGS,217416%,0.00314,19.8,8570
PUB,179900%,0.009,135.0,34449
RMP,121082%,0.03,78.54985,120487
CTZ,120300%,0.005,26.73,52050
CCD,111250%,0.015,25.55,105416
SAB,110429%,1.3985,318800.0,1695378
KE,99400%,0.015,22.2,73249
LN,96700%,0.015,49.63,394344
GHG,64850%,0.005,24.31,607659
```

Figura 13: Esercizio 1 in Hadoop, Hive, Spark

HADOOP EX2 BASIC

```
SETTORE,ANNO,VOLUME_ANNUALE_MEDIO,VARIAZIONE_ANNUALE_MEDIA_%,QUOTAZIONE_GIORNALIERA_MEDIA
BASIC INDUSTRIES,2008       560950485,-42.05%,40.0
BASIC INDUSTRIES,2009       589384165,82.32%,25.7
BASIC INDUSTRIES,2010       476571424,32.89%,32.35
BASIC INDUSTRIES,2011       448450099,-11.34%,42.74
BASIC INDUSTRIES,2012       377483105,8.19%,42.37
BASIC INDUSTRIES,2013       367271657,18.85%,133.95
BASIC INDUSTRIES,2014       350472233,-3.35%,109.44
BASIC INDUSTRIES,2015       388588042,123.46%,40.48
BASIC INDUSTRIES,2016       470968318,47.54%,31.4
BASIC INDUSTRIES,2017       383340553,16.69%,35.56
BASIC INDUSTRIES,2018       232851237,-4.05%,37.82
```

HIVE EX2 BASIC

```
BASIC INDUSTRIES,2008,560950485,-42.05,40.0
BASIC INDUSTRIES,2009,589384165,82.32,25.7
BASIC INDUSTRIES,2010,476571424,32.89,32.35
BASIC INDUSTRIES,2011,448450099,-11.34,42.74
BASIC INDUSTRIES,2012,377483105,8.19,42.37
BASIC INDUSTRIES,2013,367271657,18.85,133.95
BASIC INDUSTRIES,2014,350472233,-3.35,109.44
BASIC INDUSTRIES,2015,388588042,123.46,40.48
BASIC INDUSTRIES,2016,470968318,47.54,31.4
BASIC INDUSTRIES,2017,383340553,16.69,35.56
BASIC INDUSTRIES,2018,232851237,-4.05,37.82
```

Figura 14: Esercizio 2 Basic in Hadoop e Hive

HADOOP EX2 COMPS

```
SETTORE,ANNO,VOLUME_ANNUALE_MEDIO,
VARIAZIONE_ANNUALE_MEDIA_%,QUOTAZIONE_GIORNALIERA_MEDIA
BASIC INDUSTRIES,2008,       560950485,-42.05%,604.1
BASIC INDUSTRIES,2009,       589384165,82.32%,224.26
BASIC INDUSTRIES,2010,       476571424,32.89%,32.13
BASIC INDUSTRIES,2011,       448450099,-11.34%,443.95
BASIC INDUSTRIES,2012,       377483105,8.19%,124.53
BASIC INDUSTRIES,2013,       367271657,18.85%,238.53
BASIC INDUSTRIES,2014,       350472233,-3.35%,233.44
BASIC INDUSTRIES,2015,       390174115,124.0%,41.16
BASIC INDUSTRIES,2016,       472822524,47.85%,30.67
BASIC INDUSTRIES,2017,       384814939,16.81%,35.03
BASIC INDUSTRIES,2018,       233739982,-4.02%,37.55
```

HIVE EX2 COMPLEX

```
BASIC INDUSTRIES,2008,560950485,-42.05,604.1
BASIC INDUSTRIES,2009,589384165,82.32,224.26
BASIC INDUSTRIES,2010,476571424,32.89,32.13
BASIC INDUSTRIES,2011,448450099,-11.34,443.94
BASIC INDUSTRIES,2012,377483105,8.19,124.53
BASIC INDUSTRIES,2013,367271657,18.85,238.53
BASIC INDUSTRIES,2014,350472233,-3.35,233.44
BASIC INDUSTRIES,2015,390174115,124.0,41.16
BASIC INDUSTRIES,2016,472822524,47.85,30.67
BASIC INDUSTRIES,2017,384814939,16.81,35.03
BASIC INDUSTRIES,2018,233739982,-4.02,37.55
```

SPARK EX2

```
SETTORE,ANNO,VOLUME_ANNUALE_MEDIO,
VARIAZIONE_ANNUALE_MEDIA_%,QUOTAZIONE_GIORNALIERA_MEDIA
BASIC INDUSTRIES,2008,560950485,-42.05%,604.1
BASIC INDUSTRIES,2009,589384165,82.32%,224.26
BASIC INDUSTRIES,2010,476571424,32.89%,32.13
BASIC INDUSTRIES,2011,448450099,-11.34%,443.95
BASIC INDUSTRIES,2012,377483105,8.19%,124.53
BASIC INDUSTRIES,2013,367271657,18.85%,238.53
BASIC INDUSTRIES,2014,350472233,-3.35%,233.44
BASIC INDUSTRIES,2015,390174115,124.0%,41.16
BASIC INDUSTRIES,2016,472822524,47.85%,30.67
BASIC INDUSTRIES,2017,384814939,16.81%,35.03
BASIC INDUSTRIES,2018,233739982,-4.02%,37.55
```

Figura 15: Esercizio 2 Complex in Hadoop, Hive, Spark

Si osservi che:

- per i primi tre casi, (rispettivamente illustrati in Figura 13, 14 e 15), i risultati siano equivalenti sia in termini di valori che di ordinamento.
- per quanto concerne gli ultimi due, ovvero quelli relativi all'esercizio 3 e alla sua versione facoltativa (in Figura 16 e 17), benché i risultati siano coerenti e ordinati nella sequenza dei set di aziende con trend comune, distinte tecnologie (in particolare Spark) possano fornire distinti ordinamenti dei record a parità di numero di aziende nel set e all'interno di ciascun set. Si è pensato dunque di integrare l'output di questo esercizio con il numero di aziende con lo stesso trend, così da semplificarne il confronto visivo: inoltre per tale ragione sono stati allegati a questa relazione i risultati completi dei job in Spark (cartella *resultsComplete*), così da poterne verificare l'equivalenza rispetto ai corrispondenti in Hadoop e Hive.
- per la versione facoltativa in Figura 17 siano stati volutamente omessi alcuni risultati iniziali, al fine di mostrare anche record con i valori di similarità.

HADOOP EX3

```
n. aziende trend comune,{AZIENDE_CON_TREND_COMUNE}:,   2016: VAR_ANN_%,2017: VAR_ANN_%,2018: VAR_ANN_%
10,{EATON VANCE NEXTSHARES TRUST,VANGUARD SHORT-TERM TREASURY ETF,WISDOMTREE BARCLAYS INTEREST RATE HEDGED U.S. AGGREGATE BOND F,ISHARES 1-3 YEAR CREDIT BOND ETF,ISHARES SHORT
TREASURY BOND ETF,IVY NEXTSHARES,FIRST TRUST ENHANCED SHORT MATURITY ETF,POWERSHARES VARIABLE RATE INVESTMENT GRADE PORTFOLIO,ISHARES 1-3 YEAR TREASURY BOND ETF,ISHARES 0-5 YEAR
INVESTMENT GRADE CORPORATE BOND ETF}:         2016:0%,2017:0%,2018:0%
7,{VANGUARD MORTGAGE-BACKED SECURITIES ETF,VANGUARD INTERMEDIATE-TERM TREASURY ETF,VANGUARD SHORT-TERM CORPORATE BOND ETF,ISHARES 3-7 YEAR TREASURY BOND ETF,ISHARES GNMA BOND
ETF,POWERSHARES LADDERRITE 0-5 YEAR CORPORATE BOND PORTFOLIO,ISHARES CORE 1-5 YEAR USD BOND ETF}:    2016:0%,2017:0%,2018:-1%
3,{EATON VANCE HIGH INCOME 2021 TARGET TERM TRUST,ISHARES INTERMEDIATE CREDIT BOND ETF,ETF SERIES SOLUTIONS TRUST VIDENT CORE U.S. BOND STRATEGY FUND}:     2016:0%,2017:0%,2018:-2%
2,{"SYPRIS SOLUTIONS, INC.",VIRTUS LIFESCI BIOTECH CLINICAL TRIALS ETF}:  2016:-33%,2017:53%,2018:14%
2,{KAYNE ANDERSON ENERGY DEVELOPMENT COMPANY,"COMSTOCK RESOURCES, INC."}: 2016:10%,2017:-11%,2018:3%
2,{STANTEC INC,NUVEEN DIVERSIFIED DIVIDEND AND INCOME FUND}:    2016:4%,2017:9%,2018:-9%
2,{SPDR DORSEY WRIGHT FIXED INCOME ALLOCATION ETF,INVESCO TRUST FOR INVESTMENT GRADE MUNICIPALS}:    2016:-4%,2017:3%,2018:-7%
2,{LOCKHEED MARTIN CORPORATION,BOOKING HOLDINGS INC.}: 2016:17%,2017:26%,2018:0%
2,{"PRICESMART, INC.",NUVEN MORTGAGE OPPORTUNITY TERM FUND 2}:  2016:3%,2017:2%,2018:-2%
2,{"CENTERPOINT ENERGY, INC.",SCORPIO BULKERS INC.}:   2016:34%,2017:15%,2018:0%
```

HIVE EX3

```
10,{EATON VANCE NEXTSHARES TRUST;FIRST TRUST ENHANCED SHORT MATURITY ETF;ISHARES 0-5 YEAR INVESTMENT GRADE CORPORATE BOND ETF;ISHARES 1-3 YEAR CREDIT BOND ETF;ISHARES 1-3 YEAR
TREASURY BOND ETF;ISHARES SHORT TREASURY BOND ETF;IVY NEXTSHARES;POWERSHARES VARIABLE RATE INVESTMENT GRADE PORTFOLIO;VANGUARD SHORT-TERM TREASURY ETF;WISDOMTREE BARCLAYS INTEREST
RATE HEDGED U.S. AGGREGATE BOND F},2016:0%;2017:0%;2018:0%
7,{ISHARES 3-7 YEAR TREASURY BOND ETF;ISHARES CORE 1-5 YEAR USD BOND ETF;ISHARES GNMA BOND ETF;POWERSHARES LADDERRITE 0-5 YEAR CORPORATE BOND PORTFOLIO;VANGUARD INTERMEDIATE-TERM
TREASURY ETF;VANGUARD MORTGAGE-BACKED SECURITIES ETF;VANGUARD SHORT-TERM CORPORATE BOND ETF},2016:0%;2017:0%;2018:-1%
3,{EATON VANCE HIGH INCOME 2021 TARGET TERM TRUST;ETF SERIES SOLUTIONS TRUST VIDENT CORE U.S. BOND STRATEGY FUND;ISHARES INTERMEDIATE CREDIT BOND ETF},2016:0%;2017:0%;2018:-2%
2,{"SYPRIS SOLUTIONS, INC.",VIRTUS LIFESCI BIOTECH CLINICAL TRIALS ETF}:  2016:-33%,2017:53%,2018:14%
2,{KAYNE ANDERSON ENERGY DEVELOPMENT COMPANY,"COMSTOCK RESOURCES, INC."}: 2016:10%,2017:-11%,2018:3%
2,{STANTEC INC,NUVEEN DIVERSIFIED DIVIDEND AND INCOME FUND}:    2016:4%,2017:9%,2018:-9%
2,{SPDR DORSEY WRIGHT FIXED INCOME ALLOCATION ETF,INVESCO TRUST FOR INVESTMENT GRADE MUNICIPALS}:    2016:-4%,2017:3%,2018:-7%
2,{LOCKHEED MARTIN CORPORATION,BOOKING HOLDINGS INC.}: 2016:17%,2017:26%,2018:0%
2,{"PRICESMART, INC.",NUVEN MORTGAGE OPPORTUNITY TERM FUND 2}:  2016:3%,2017:2%,2018:-2%
2,{"CENTERPOINT ENERGY, INC.",SCORPIO BULKERS INC.}:   2016:34%,2017:15%,2018:0%
```

SPARK EX3

```
n. aziende trend comune,{AZIENDE_CON_TREND_COMUNE}:,2016: VAR_ANN_%,2017: VAR_ANN_%,2018: VAR_ANN_%
10,{EATON VANCE NEXTSHARES TRUST,VANGUARD SHORT-TERM TREASURY ETF,ISHARES SHORT TREASURY BOND ETF,IVY NEXTSHARES,ISHARES 1-3 YEAR CREDIT BOND ETF,POWERSHARES VARIABLE RATE INVESTMENT
GRADE PORTFOLIO,ISHARES 1-3 YEAR TREASURY BOND ETF,ISHARES 0-5 YEAR INVESTMENT GRADE CORPORATE BOND ETF,WISDOMTREE BARCLAYS INTEREST RATE HEDGED U.S. AGGREGATE BOND F,FIRST TRUST
ENHANCED SHORT MATURITY ETF}: ,2016: 0%,2017: 0%,2018: 0%
7,{ISHARES 3-7 YEAR TREASURY BOND ETF,ISHARES CORE 1-5 YEAR USD BOND ETF,ISHARES GNMA BOND ETF,VANGUARD MORTGAGE-BACKED SECURITIES ETF,POWERSHARES LADDERRITE 0-5 YEAR CORPORATE BOND
PORTFOLIO,VANGUARD INTERMEDIATE-TERM TREASURY ETF,VANGUARD SHORT-TERM CORPORATE BOND ETF}: ,2016: 0%,2017: 0%,2018: -1%
3,{ISHARES INTERMEDIATE CREDIT BOND ETF,EATON VANCE HIGH INCOME 2021 TARGET TERM TRUST,ETF SERIES SOLUTIONS TRUST VIDENT CORE U.S. BOND STRATEGY FUND}: ,2016: 0%,2017: 0%,2018: -2%
2,{"COMSTOCK RESOURCES, INC.",KAYNE ANDERSON ENERGY DEVELOPMENT COMPANY}: ,2016: 10%,2017: -11%,2018: 3%
2,{AZZ INC.,"WESTERN GAS PARTNERS, LP"}: ,2016: 21%,2017: -20%,2018: 5%
2,{NUVEN MORTGAGE OPPORTUNITY TERM FUND 2,"PRICESMART, INC."}: ,2016: 3%,2017: 2%,2018: -2%
2,{"SYPRIS SOLUTIONS, INC.",VIRTUS LIFESCI BIOTECH CLINICAL TRIALS ETF}: ,2016: -33%,2017: 53%,2018: 14%
2,{FIRST TRUST INTERNATIONAL MULTI-ASSET DIVERSIFIED INCOME INDEX,FIRST TRUST RIVERFRONT DYNAMIC ASIA PACIFIC ETF}: ,2016: -1%,2017: 16%,2018: -8%
2,{STORE CAPITAL CORPORATION,SEMPRA ENERGY}: ,2016: 8%,2017: 5%,2018: 10%
2,{"TEMPLETON GLOBAL INCOME FUND, INC.",REGENCY CENTERS CORPORATION}: ,2016: 2%,2017: 0%,2018: -5%
```

Figura 16: Esercizio 3 in Hadoop, Hive, Spark

HIVE EX3 STANDARD

```
{EATON VANCE NEXTSHARES TRUST;FIRST TRUST ENHANCED SHORT MATURITY ETF;ISHARES 0-5 YEAR INVESTMENT GRADE CORPORATE BOND ETF;ISHARES 1-3 YEAR CREDIT BOND ETF;ISHARES 1-3 YEAR TREASURY
BOND ETF;ISHARES SHORT TREASURY BOND ETF;IVY NEXTSHARES;POWERSHARES VARIABLE RATE INVESTMENT GRADE PORTFOLIO;VANGUARD SHORT-TERM TREASURY ETF;WISDOMTREE BARCLAYS INTEREST RATE HEDGED
U.S. AGGREGATE BOND F},2016:0%;2017:0%;2018:0%
{ISHARES 3-7 YEAR TREASURY BOND ETF;ISHARES CORE 1-5 YEAR USD BOND ETF;ISHARES GNMA BOND ETF;POWERSHARES LADDERRITE 0-5 YEAR CORPORATE BOND PORTFOLIO;VANGUARD INTERMEDIATE-TERM
TREASURY ETF;VANGUARD MORTGAGE-BACKED SECURITIES ETF;VANGUARD SHORT-TERM CORPORATE BOND ETF},2016:0%;2017:0%;2018:-1%
{EATON VANCE HIGH INCOME 2021 TARGET TERM TRUST;ETF SERIES SOLUTIONS TRUST VIDENT CORE U.S. BOND STRATEGY FUND;ISHARES INTERMEDIATE CREDIT BOND ETF},2016:0%;2017:0%;2018:-2%
{"SYPRIS SOLUTIONS, INC.",VIRTUS LIFESCI BIOTECH CLINICAL TRIALS ETF}:    2016:-33%,2017:53%,2018:14%
{KAYNE ANDERSON ENERGY DEVELOPMENT COMPANY,"COMSTOCK RESOURCES, INC."}:   2016:10%,2017:-11%,2018:3%
{STANTEC INC,NUVEEN DIVERSIFIED DIVIDEND AND INCOME FUND}:      2016:4%,2017:9%,2018:-9%
{SPDR DORSEY WRIGHT FIXED INCOME ALLOCATION ETF,INVESCO TRUST FOR INVESTMENT GRADE MUNICIPALS}:      2016:-4%,2017:3%,2018:-7%
{LOCKHEED MARTIN CORPORATION,BOOKING HOLDINGS INC.}:    2016:17%,2017:26%,2018:0%
{"PRICESMART, INC.",NUVEN MORTGAGE OPPORTUNITY TERM FUND 2}:    2016:3%,2017:2%,2018:-2%
{"CENTERPOINT ENERGY, INC.",SCORPIO BULKERS INC.}:     2016:34%,2017:15%,2018:0%
```

HIVE EX3 FACOLTATIVO

```
... (all results with same trends as always)
{ADVENT/CLAYMORE ENHANCED GROWTH & INCOME FUND;BLACKROCK MUNIYIELD INVESTMENT QUALITYFUND},2016:0%;2017:0%;2018:-7%
{ALLIANZGI CONVERTIBLE & INCOME FUND II;TPG SPECIALTY LENDING, INC.},2016:13%;2017:7%;2018:0%
{AMERICA FIRST MULTIFAMILY INVESTORS, L.P.;FLEXSHARES REAL ASSETS ALLOCATION INDEX FUND},2016:6%;2017:12%;2018:-2%
{1ST CONSTITUTION BANCORP (NJ);CNB FINANCIAL CORPORATION;HORIZON BANCORP, INC.;},similarity = 5
{1ST CONSTITUTION BANCORP (NJ);ENVIVA PARTNERS, LP;HORIZON BANCORP, INC.;WASHINGTON TRUST BANCORP, INC.;},similarity = 5
{ABERDEEN GLOBAL DYNAMIC DIVIDEND FUND;DNB FINANCIAL CORP;INDIA FUND, INC. (THE);},similarity = 5
{ABERDEEN INCOME CREDIT STRATEGIES FUND;CUSHING ENERGY INCOME FUND (THE);EATON VANCE FLOATING-RATE INCOME PLUS FUND;HIGHWOODS PROPERTIES, INC.;TALLGRASS ENERGY PARTNERS, LP;WHITESTONE
REIT;},similarity = 5
{ABERDEEN INCOME CREDIT STRATEGIES FUND;DUFF & PHELPS UTILITIES INCOME, INC.;HIGHWOODS PROPERTIES, INC.;},similarity = 5
{ABERDEEN TOTAL DYNAMIC DIVIDEND FUND;GENPACT LIMITED;RYANAIR HOLDINGS PLC;SKYWORKS SOLUTIONS, INC.;},similarity = 5
{ACCENTURE PLC;AMERICAN STATES WATER COMPANY;ROGERS COMMUNICATION, INC.;},similarity = 5
```

Figura 17: Esercizio 3 Main e Facoltativo in Hive

7 Performance Test

In questa Sezione sono descritte le tipologie di test effettuati sulle implementazioni dei tre esercizi, in tutte le tecnologie, e sono illustrati con tabelle e grafici i risultati ottenuti.
Sono stati eseguiti molteplici test di performance sui job richiesti. Tra le versioni implementate degli esercizi e sopra discusse, sono state considerate per la fase di testing solo quelle che presentassero differenze rilevanti a livello implementativo, quali il numero di job MapReduce in chain o la presenza o meno del combiner: versioni invece che si distinguono solo per il formato in output non sono state soggette a test specifici poiché considerati non rilevanti per il lavoro in questione.
I test effettuati mirano alla verifica delle performance e della scalabilità delle tecnologie utilizzate, ovvero:

- Hadoop 3.2.1
- Hive 2.3.6 e 3.1.2;
- Spark 3.0.0 .

A tal fine si sono utilizzati e sono stati messi a confronto diversi ambienti di esecuzione, quali:

- VM *superiore*, con buon livello di hardware dedicato: 4 processori, 8GB di RAM, 30GB HDD.
- VM *inferiore*, con scarso livello di hardware dedicato: 2 processori, 4GB di RAM, 30GB HDD.
- 3 istanze di nodi *m5.xlarge* su cluster AWS.

Al fine di verificare la scalabilità dei job creati, sono stati considerati sia i dati originali (*Normal input*) che le versioni replicate 3 volte degli stessi (*Big input*), per poter osservare il nuovo comportamento a fronte di dataset sensibilmente più grandi. I valori riferiti ai test di scalabilità su *Big input* si riferiscono a esecuzioni effettuate sulla sola VM *superiore* e su cluster.
A seguito dell'esecuzione dei test, sono stati creati dei grafici, riportati nell'ultima pagina di questo documento, per poter visualizzare e confrontare diversi aspetti.
In Sezione 7.1 sono presentati i tempi medi per l'esecuzione dei vari esercizi e nelle diverse tecnologie. In Sezione 7.2 sono illustrati e descritti i grafici comparativi costruiti a partire da tali tempi.

7.1 Tabelle Risultati

La modalità con la quale i vari Job sono stati eseguiti è attraverso il comando *time* della shell Unix, riportando il valore associato a *real*, ovvero il tempo trascorso dall'inizio alla fine della chiamata del comando. Ogni esecuzione è stata ripetuta più volte ed è stata effettuata una media dei valori rilevati.
Di seguito sono fornite le tabelle con i tempi medi per le esecuzioni di ciascun Job in ciascuna tecnologia. Si rimanda a Sezione 7.2 per grafici e confronti.

Locale-VM Inferiore	Hadoop	Hive	Spark
normal	49s	3m 21s	26s
Locale-VM Superiore	Hadoop	Hive	Spark
normal	45s	*main* 2m 25s *altern* 2m 27s	18s
biginput	1m 36s	*main* 7m 9s *altern* 7m 11s	38s
Cluster	Hadoop	Hive	Spark
normal	59s	1m 44s	37s
biginput	2m 19s	3m 17s	1m 44s

Figura 18: Tempi Esecuzioni Job 1

Locale-VM Inferiore	Hadoop	Hive	Spark
normal	*basic* 1m 47s *complex* 2m 18s *combiner* 2m 17s	*basic* 2m 54s *complex* 3m 50s	*singlerow* 1m 53s *distributedrow* 1m 2s
Locale-VM Superiore	Hadoop	Hive	Spark
normal	*basic* 1m 36s *complex* 2m 16s *combiner* 2m 16s	*basic* 1m 47s *complex* 3m 11s	*singlerow* 1m 15s *distributedrow* 0m 43s
biginput	*basic* 6m 47s *complex* 7m 50s *combiner* 7m 49s	*basic* 9m 55s *complex* 11m 53s	*singlerow* 3m 11s *distributedrow* 3m 15s
Cluster	Hadoop	Hive	Spark
normal	*basic* 2m 25s *complex* 3m 18s *combiner* 2m 50s	*basic* 1m 31s *complex* 5m 46s	*singlerow* 1m 31s *distributedrow* 58s
biginput	*basic* 3m 15s	*basic* 4m 27s	*singlerow* 2m 55s

Figura 19: Tempi Esecuzioni Job 2

Locale-VM Inferiore	Hadoop	Hive	Spark
normal	46s	3m 10s	56s
Locale-VM Superiore	Hadoop	Hive	Spark
normal	34s	*main* 2m 14s *altern* 2m 16s	32s
biginput	1m 37s	*main* 5m 22s *altern* 5m 48s	1m 24s
Cluster	Hadoop	Hive	Spark
normal	1m 28s	1m 44s	54s
biginput	2m 53s	5m 11s	1m 46s

Figura 20: Tempi Esecuzioni Job 3

7.2 Grafici e Confronti

Di seguito sono forniti i grafici ricavati a partire dai tempi di cui sopra. Sono state effettuate molteplici e distinte comparazioni, non solo tra le tecnologie ma anche tra versioni diverse di un esercizio implementate nella stessa tecnologia. In tutti i grafici di seguito presentati, il tempo è espresso in secondi.

Possiamo fare alcune osservazioni per ciascun test.

- **Grafico (a).** Confronto complessivo dei tempi di esecuzione in Hadoop al variare della dimensione dei dati in input e della macchina sulla quale viene eseguito il Job. Da questi risultati è possibile effettuare diverse considerazioni.
  - Job2, sia nella sua versione *Basic* che in quella *Complex*, risulta il più costoso da eseguire; inoltre è quello con maggiori variazioni nei tempi al crescere della dimensione dei file in input.
  - Per un input *Normal*, al variare delle prestazioni della VM, non è osservabile una rilevante differenza di tempistiche: questo può far riflettere sul fatto che Hadoop non ottimizzi automaticamente l'esecuzione sulla base delle risorse disponibili, ma che queste debbano essere gestite manualmente tramite un opportuno file di configurazione.
  - Interessante notare che, se da un lato per il Job1 e il Job3 l'esecuzione di *Big Input* su cluster richieda maggior tempo rispetto al corrispondente locale, nel caso di Job2 *Basic* sia esattamente l'opposto.
  - Nel complesso, i tempi richiesti risultano intermedi rispetto ai corrispondenti in Hive e Spark.
- **Grafico (b).** Confronto complessivo dei tempi di esecuzione in Hive al variare della dimensione dei dati in input e della macchina sulla quale viene eseguito il Job. Per Hive è possibile effettuare simili considerazioni rispetto ad Hadoop, con alcune differenze.
  - Job1 e Job2 *basic* si sono rilevati essere più efficienti su Cluster.
  - Nel Job3 si può osservare un maggior equilibrio tra i tempi di esecuzione di *Big Input* in locale e su Cluster.
  - Nel complesso, i tempi richiesti per l'esecuzione in Hive sono, come prevedibile, superiori in confronto ai corrispettivi in Hadoop e soprattutto Spark.
- **Grafico (c).** Confronto complessivo dei tempi di esecuzione in Spark al variare della dimensione dei dati in input e della macchina sulla quale viene eseguito il Job. Le considerazioni che è possibile effettuare su Spark sono le seguenti.
  - Job1 e Job3 rispondono con particolare efficienza al variare della dimensione in input e della macchina sul quale vengono eseguiti.
  - Job2 ha subito un forte incremento delle tempistiche al crescere dell'input, atteso vista la complessità del job stesso, che richiede più fasi di elaborazione e quindi un corrispettivo overhead non indifferente.
  - La differenza di prestazioni ottenuta tra VM con un buon livello di hardware dedicato e VM con livello di hardware inferiore è più apprezzabile rispetto alle corrispondenti in Hadoop e Hive. Questo è prova che Spark sia più efficiente quando abbia a disposizione più RAM e processori, e che sia in grado di sfruttare tale differenza. Da notare che anche Spark permetta di gestire manualmente, tramite file di configurazione, la quantità di memoria RAM utilizzabile.
  - Nel complesso, salvo rare eccezioni, con Spark si sono ottenuti i risultati migliori in termini di tempo per ogni Job testato.
- **Grafico (d),(e),(f).** Confronto dei tempi di esecuzione per le versioni principali dei Job, al variare della tecnologia utilizzata e al variare dell'ambiente di esecuzione. Questi grafici permettono di osservare quanto segue.
  - Job2 è quello che richiede un'elaborazione maggiore in ogni scenario testato, mentre per Job1 e Job3 ciò varia in base alla tecnologia.

  - Job1 e Job3 risulta particolarmente beneficiato dall'uso del Cluster.
  - Come già osservato, la tecnologia più efficiente è Spark, a prescindere dalla tipologia del Job e della macchina utilizzata.

- **Grafico (g).** Confronto dei tempi di esecuzione in Hadoop del Job 2 se si utilizzino o meno dei Combiner per aumentare la sua efficienza. È interessante osservare che le prestazioni siano quasi invariate, questo è dovuto alla natura del dataset ed alla tipologia di elaborazioni richieste dal job stesso: si ricorda difatti che l'uso di Combiner in MapReduce sia suggerito in casi quali la presenza di un elevato numero di output associati a una stessa chiave in uscita da un Mapper.

- **Grafico (h).** Confronto dei tempi di esecuzione in Hadoop e Hive del Job2 tra le implementazioni *Basic* e *Complex*. Prevedibilmente, la versione più semplice, che richiede uno step Map-Reduce in meno rispetto alla sua versione complessa, presenta tempi inferiori in entrambe le tecnologie.

- **Grafico (i).** Confronto dei tempi di esecuzione in Spark del Job2 tra le implementazioni SingleRow e DistributedRows. È possibile osservare come, su un input *Normal*, gestire dei risultati intermedi porti a dei benefici in termini di tempo, mentre su input di grandi dimensioni Spark riesca a gestire efficientemente l'esecuzione, anche con prestazioni leggermente migliori, qualora le funzioni fossero utilizzate in un'unica riga.

- **Grafico (j).** Confronto dei tempi di esecuzione in Hive del Job 1 e Job 3 tra le versioni *main* e *altern*, al fine di comprendere l'impatto delle variazioni sulle prestazioni. Dai risultati si può osservare che la presenza di tabelle temporanee non abbia mostrato conseguenze in termini di tempo impiegato per l'esecuzione (Job1); simile affermazione si può sostenere per la diversa procedura di calcolo per la variazione di quotazione (Job3).

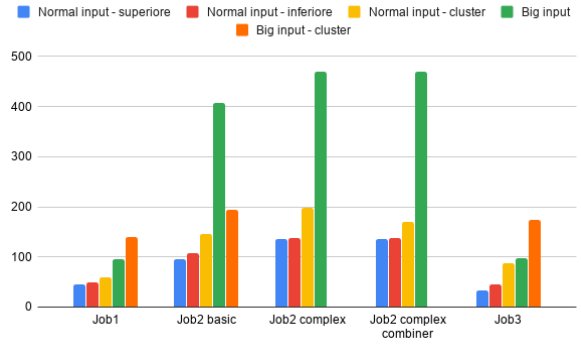

(a) Confronto esecuzione al variare di input e macchina - Hadoop

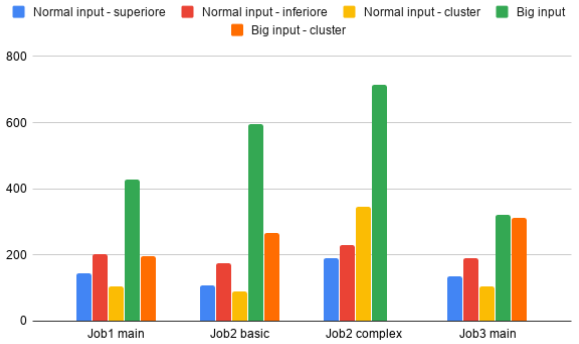

(b) Confronto esecuzione al variare di input e macchina - Hive

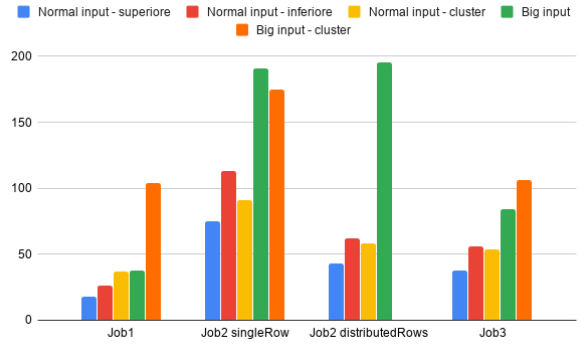

(c) Confronto esecuzione al variare di input e macchina - Spark

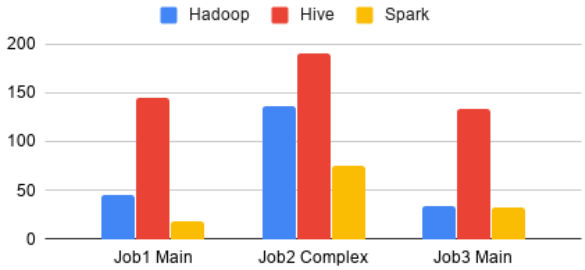

(d) Confronto tecnologie - VM superiore

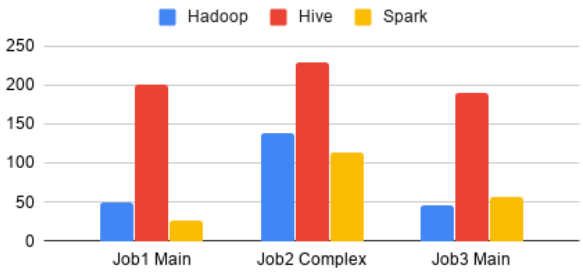

(e) Confronto tecnologie - VM inferiore

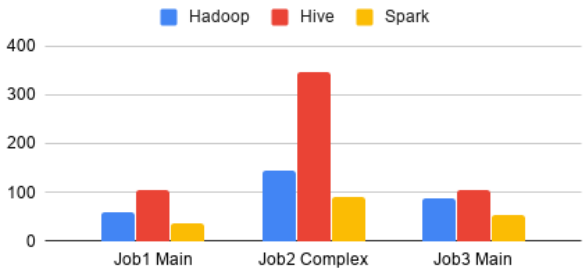

(f) Confronto tecnologie - Cluster AWS

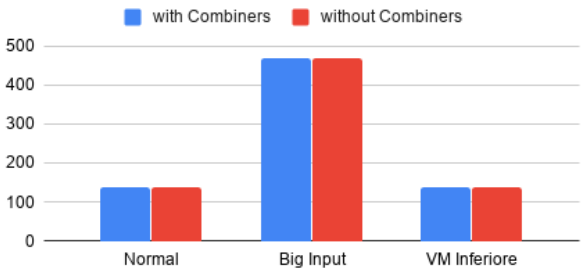

(g) Job2 Hadoop con vs senza Combiners

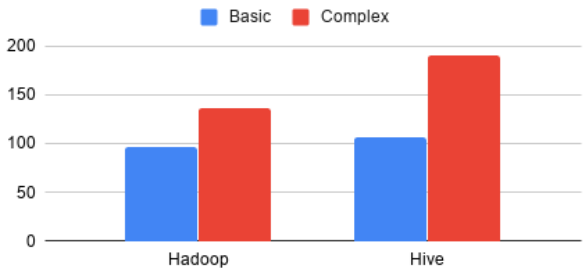

(h) Job2 Hive versione Basic vs Complex

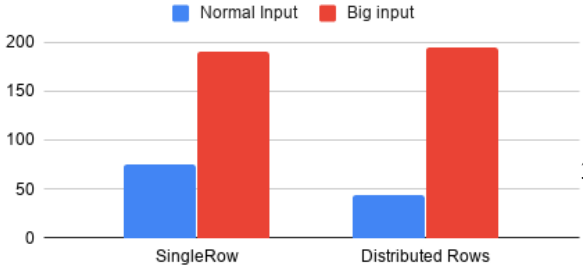

(i) Job2 Spark versione Single vs Distributed

(j) Job1 Job3 Hive Main vs Altern

8 Conclusioni

Questa relazione ha descritto le varie fasi del lavoro svolto come primo progetto del corso ”Big Data”. L'obiettivo di questa attività è stato l'impiego delle tecnologie Hadoop, Hive e Spark per lo svolgimento di job MapReduce applicati a scenari. Inoltre è stata caratterizzata da una consistente implementazione in varie versioni, sulla base delle specifiche fornite e delle successive discussioni con il docente, così come da una intensa attività di testing di queste ultime, al fine di comprendere vantaggi e svantaggi dei vari approcci. Dall'esperienza fornitaci dallo svolgimento di questo progetto, è possibile sottolineare i seguenti aspetti:

- **Spark**: con riferimento ai risultati ottenuti durante la fase di testing, risulta che Spark sia la tecnologia più efficiente. Essa spicca anche per la facilità e velocità di scrittura del codice, della documentazione e della leggibilità del codice prodotto.
- **Hadoop**: permette di ottenere buoni risultati in termini di performance e risulta abbastanza semplice scriverne e documentarne il codice.
- **Hive**: si è rivelata essere la peggiore, paragonata alle altre due tecnologie sopracitate, sia in termini di performance, sia in termini di facilità di scrittura del codice in quanto, anche se SQL è un linguaggio estremamente familiare, risulta meno intuitivo scrivere delle interrogazioni per elaborazioni complesse. Di contro presenta il vantaggio dell'estrema sinteticità, oltre alla già citata familiarità con lo standard SQL e alla facilità di documentare le interrogazioni prodotte.